



UNIVERSIDADE PREBISTERIANA MACKENZIE – CIÊNCIA DE DADOS - PROJETO APLICADO III


SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

Grupo 14: Rayan Crhistofer, Amanda Schwantes, Thábata Cristina e Tiago Riuji

INTRODUÇÃO

O ensino a distância (EaD) cresceu 474% entre 2011 e 2021, ampliando o acesso à educação, mas também elevando os desafios, como alta evasão (cerca de 59% no EaD) e baixo engajamento. A pandemia agravou o cenário, afetando o desempenho de 30,5% dos estudantes, somado a problemas como desigualdade digital e distrações com redes sociais.

Este projeto propõe um sistema inteligente de recomendação para identificar alunos que necessitam de apoio acadêmico, utilizando dados de engajamento em cursos online. A solução visa apoiar professores e tutores na tomada de decisões pedagógicas, contribuindo com o ODS 4 – Educação de Qualidade.




Comodidade é um dos principais motivos para estudar à distância

quem EAD pela flexibilidade. Mensalidades são 50% mais baratas em relação ao ensino presencial

pelo ensino à distância. "A mensalidade é 50% mais barata do que a de um curso presencial", explicou Toniolo. Mas também há dificuldades. A dos estudantes da área de tecnologia, segundo Toniolo, é com a linguagem de programação, e ela não se restringe ao ensino à distância. "As pessoas entram na área da informática e acreditam que tudo é mil maravilhas, porque o salário é bom. Mas esquecem que é preciso estudar muito para chegar lá."

Segundo o coordenador pedagógico de EAD da Fiap, Henrique Poyatos, o principal motivo de jovens escolherem a área da tecnologia é a boa remuneração. "É um setor que está bem aquecido, mesmo com a crise. Existem milhares de vagas não preenchidas e os salários só vão melhorando".

Não são todos os estudantes, no entanto, que optam por essa carreira pensando só no retorno financeiro. "Cursei o tecnólogo



ENTREVISTA

Henrique Poyatos, Coord. pedagógico de EAD da Fiap

EAD pode ser modelo para atingir outros públicos

A educação à distância é vista por alguns profissionais da área como uma alternativa de acesso ao ensino superior. Segundo o coordenador pedagógico de EAD da Fiap (Faculdade de Informática e Administração Paulista) esse modelo está crescendo e tem dado acesso a um público interessante.



Como são sanadas essas dúvidas à distância?

A mais comum é pelo fórum da plataforma. O aluno publica e o tutor responde, porém há estudantes mais reservados, por isso ele pode enviar sua dúvida por e-mail. Procuramos dar uma resposta em até 24 horas. O importante é o aluno não se sentir abandonado.

O estudante de EAD tem alguma desvantagem no mercado de trabalho?

Não, as empresas estão aceitando cada vez mais esse modelo. Hoje, o empregador olha a seriedade da instituição e não se o curso é presencial.

TECNOLOGIA E DISTÂNCIA

Mercado de trabalho tecnológico pede por mais profissionais no setor. Remuneração alta é o que chama atenção de estudantes da área de TI




Média por turma EAD é de 31 a 50 alunos
De acordo com um estudo realizado pela Abed (Associação Brasileira de Educação a Distância), a quantidade média de estudantes em cursos na modalidade EAD concentra-se em turmas de 31 a 50 matriculados.

13 mil educadores atuam no Brasil para atender alunos de EAD

Ciências sociais aplicadas faz sucesso
Em 2014, a área mais popular entre os cursos regulamentados totalmente à distância foi o de ciências humanas, que teve 25% das matrículas, enquanto gestão e negócios, 21%.

Novos alunos em EAD x presencial

Proporção de ingressantes no ensino superior, por modalidade



Fonte: Censo de Educação Superior (Inep)

Infográfico elaborado em: 22/10/2020



Curso é a aula

para aproveitar mais as redes. "Admito que não estrutura física que é Quando fui fazer a prova unidade tinha biblioté- rios. Por morar lon- ção indo até lá", disse. r suas dúvidas, ele as ferramentas dis- as na plataforma on- li- muito. "Se o aluno consegue se adaptar, ele conse- gue trabalhar sozinho. Não tem segredo nenhum", afirmou.


Outro aspecto que motivou Fernando a cursar gestão de TI foi a chance de melhorar seu conhecimento teórico, já que trabalha na área há mais de dez anos. "Tudo que aprendo em um dia, no outro já coloco em prática."

sante do EAD é a possibilidade de você retomar quantas vezes quiser uma aula que não entendeu", afirmou Fernando.

Entretanto, ele também admitiu



OBJETIVOS DO PROJETO



Objetivo Geral

Desenvolver um sistema de recomendação que identifique alunos com dificuldades em cursos online e sugira tutores adequados, promovendo uma educação mais personalizada e eficiente.



Objetivos específicos:


- Analisar dados de engajamento e desempenho dos alunos.
- Aplicar técnicas de aprendizado de máquina para prever a necessidade de tutoria.
- Avaliar o sistema com diferentes abordagens e métricas.
- Criar um dashboard para visualização das recomendações.
- Validar e ajustar os resultados para maior precisão e relevância.

REFERÊNCIAL TEORICO




ODS e Educação Personalizada

- Alinhado ao ODS 4 da ONU: garantir educação de qualidade para todos.
- Desafio: evasão em cursos online por falta de personalização e suporte individual (Kizilcec et al., 2017).




Sistemas de Recomendação Educacionais

- Utilizam IA e dados para sugerir cursos, materiais e tutores (Ricci et al., 2015).
- Coursera e edX aumentaram em 15% a taxa de conclusão com uso desses sistemas (Xu et al., 2022).



Modelos de recomendação

- Modelo de aprendizado supervisionado aplicado a sistemas de recomendação educacional: KNN



Engajamento e Retenção


- Intervenções personalizadas aumentam permanência e sentimento de pertencimento (Anderson et al., 2020).
- Gamificação e comunidades virtuais também são estratégias eficazes (Limniou & Smith, 2020).

REFERÊNCIAL TEORICO




Tutoria como Estratégia Pedagógica

- Acompanhamento individual melhora desempenho (Bloom, 1984).
- Sistemas tutores inteligentes adaptam conteúdo ao progresso do aluno (Aleven et al., 2016).
-




Desafios na Implementação

- Ética e privacidade dos dados (Dankar & Elmolhim, 2020).
- Viés algorítmico e resistência institucional (Ge et al., 2020; Martin et al., 2021).



Competências e Humanização da Tutoria

- Tutores precisam de formação digital contínua (Rojas & Riedner, 2020).
- Papel socioafetivo do tutor é essencial para engajamento e vínculo (Custódio et al., 2022).



Impactos Institucionais


- Tutoria qualificada melhora gestão do curso e apoio docente (Franco & Carmo, 2020).
- Reforça a imagem da instituição e contribui para o sucesso acadêmico.

METODOLOGIA

Este estudo adota uma abordagem quantitativa, utilizando análise exploratória de dados (EDA) e modelagem preditiva para identificar padrões de engajamento e prever a necessidade de tutoria em cursos online. A metodologia foi estruturada em três etapas principais:

1. Análise descritiva do engajamento e perfil dos alunos, com base em variáveis como número de capítulos acessados, visualizações de vídeo, dias de atividade e postagens em fóruns;
2. Investigação de correlações entre comportamento e desempenho, buscando identificar os fatores mais relevantes para prever a conclusão dos cursos;
3. Desenvolvimento de um sistema de recomendação para suporte acadêmico, focado em indicar alunos com necessidade de tutoria personalizada.





O conjunto de dados utilizado conta com mais de 640 mil registros, contendo variáveis quantitativas e demográficas. Durante o pré-processamento, foram tratadas ausências de dados (como 71,3% de valores nulos em visualizações de vídeo), transformadas variáveis categóricas em numéricas e criada a variável de idade com base no ano de nascimento. A distribuição dos dados foi considerada altamente desbalanceada, com apenas 2,8% dos alunos recebendo certificados, o que exigiu cuidados adicionais na modelagem.



ANÁLISE EXPLORATÓRIA DE DADOS

Principais Correlações e Diferenças entre Alunos



- Forte correlação entre explorados e certificados (0,68)
- Alta correlação entre eventos e dias de atividade (0,84)
- Correlação significativa entre capítulos acessados e explorados (0,80)
- Alunos certificados apresentam:
- 4 vezes mais dias ativos (mediana 100 vs 25 dias)
- Maior acesso a conteúdos (capítulos e vídeos)
- Leve vantagem em interação nos fóruns



ANÁLISE EXPLORATÓRIA DE DADOS

Perfil Demográfico dos Alunos

- Faixa etária predominante: 22 a 31 anos
- Maioria dos alunos são dos EUA
- Distribuição desigual por gênero, refletindo possível viés amostral



ANÁLISE EXPLORATÓRIA DE DADOS


Limitações e Recomendações Metodológicas

Limitações:

- Muitos dados faltantes
- Variável alvo (certificação) altamente desbalanceada
- Possível viés geográfico
- Falta de dados qualitativos complementares




Recomendações:

- Uso de técnicas avançadas para tratamento de dados faltantes
- Coleta paralela de dados qualitativos
- Modelos que considerem padrões temporais de engajamento
- Implementação de sistemas de alerta para:
 - Dias de inatividade
 - Baixo acesso a conteúdos
 - Padrões irregulares de interação





RESULTADOS: IDENTIFICAÇÃO DE PADRÕES DE ENGAJAMENTO

- Forte correlação entre engajamento e certificação (ex: dias ativos, acesso a capítulos e vídeos).
- Alunos certificados tiveram, em média, 4 vezes mais dias de atividade.
- Maior interação em fóruns observada entre alunos que concluíram o curso.




RESULTADOS: PERFIL DOS ALUNOS E ENGAJAMENTO

- Faixa etária predominante: 22 a 31 anos.
- Maioria dos alunos provenientes dos EUA.
- Distribuição desigual por gênero.



RESULTADOS: LIMITAÇÕES E INSIGHTS PARA INTERVENÇÃO

- Dados apresentaram lacunas significativas, especialmente em visualizações de vídeo e nível educacional.
- Desbalanceamento da variável de certificação (apenas 2,8% concluíram).
- Resultados indicam que monitorar dias de inatividade e acesso ao conteúdo pode ajudar a identificar alunos em risco.





DESENVOLVIMENTO DO MODELO DE RECOMENDAÇÃO ACADÊMICA

- Objetivo: Identificar alunos com risco de não obter certificação e recomendar tutoria personalizada.
- Tipo de modelo: Aprendizado supervisionado com K-Nearest Neighbors (KNN).
- Dados utilizados: Métricas de engajamento dos estudantes em cursos online (atividades, vídeos, capítulos).
- Benefício: Antecipar evasão e oferecer suporte direcionado, promovendo a permanência e o sucesso acadêmico.

```
# 1. IMPORTAR BIBLIOTECAS
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# 2. LEITURA DO DATASET (caminho corrigido)
df = pd.read_csv("/kaggle/input/online-course-student-engagement-metrics/Courses.csv")

# 3. LIMPEZA INICIAL
# Remover colunas categóricas (object) e colunas 100% nulas
df = df.drop(columns=df.select_dtypes(include=['object']).columns)
df = df.drop(columns=['roles'], errors='ignore')

# Preencher valores nulos com a média de cada coluna
df = df.fillna(df.mean(numeric_only=True))

# 4. NORMALIZAÇÃO DOS DADOS
scaler = MinMaxScaler()
df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)

# 5. SELEÇÃO DE FEATURES RELEVANTES (correlação > 0.3 com 'certified')
correlacoes = df_scaled.corr()['certified'].abs()
colunas_correlacionadas = correlacoes[correlacoes > 0.3].index.drop('certified', errors='ignore')

X = df_scaled[colunas_correlacionadas]
y = df_scaled['certified'] # 1 = certificado (não precisa de tutoria), 0 = precisa

# 6. DIVISÃO TREINO E TESTE
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 7. TREINAMENTO DO MODELO KNN
modelo_knn = KNeighborsClassifier(n_neighbors=5)
modelo_knn.fit(X_train, y_train)

# 8. AVALIAÇÃO DO MODELO
y_pred = modelo_knn.predict(X_test)

print("🔵 Avaliação do Modelo KNN:")
print("Acurácia:", accuracy_score(y_test, y_pred))
print("\nMatriz de Confusão:\n", confusion_matrix(y_test, y_pred))
print("\nRelatório de Classificação:\n", classification_report(y_test, y_pred))

# 9. VISUALIZAÇÃO DA MATRIZ DE CONFUSÃO
plt.figure(figsize=(6,4))
sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predito')
plt.ylabel('Real')
plt.title('Matriz de Confusão - KNN')
plt.show()

# 10. RECOMENDAÇÃO DE TUTORIA
df_resultados = X_test.copy()
df_resultados['precisa_tutoria'] = 1 - y_pred # 1 = precisa de tutoria
df_resultados['recomendado'] = df_resultados['precisa_tutoria'].apply(lambda x: "Sim" if x == 1 else "Não")

print("🟡 Alunos recomendados para tutoria (amostra):")
display(df_resultados[df_resultados['recomendado'] == 'Sim'].head(10))
```



ETAPAS DA CONSTRUÇÃO DO MODELO

- Bibliotecas: pandas, numpy, seaborn, matplotlib e scikit-learn.
- Pré-processamento:
- Normalização com Min-Max Scaling (escala de 0 a 1).
- Seleção de variáveis com correlação > 0,3 com a variável “certified”.
- Modelagem:
- Divisão dos dados: 80% treino / 20% teste (random_state=42).
- Algoritmo: KNN (k=5), baseado na similaridade entre alunos.

```
# 1. IMPORTAR BIBLIOTECAS
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# 2. LEITURA DO DATASET (caminho corrigido)
df = pd.read_csv("/kaggle/input/online-course-student-engagement-metrics/Courses.csv")

# 3. LIMPEZA INICIAL
# Remover colunas categóricas (object) e colunas 100% nulas
df = df.drop(columns=df.select_dtypes(include=['object']).columns)
df = df.drop(columns=['roles'], errors='ignore')

# Preencher valores nulos com a média de cada coluna
df = df.fillna(df.mean(numeric_only=True))

# 4. NORMALIZAÇÃO DOS DADOS
scaler = MinMaxScaler()
df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)

# 5. SELEÇÃO DE FEATURES RELEVANTES (correlação > 0.3 com 'certified')
correlacoes = df_scaled.corr()['certified'].abs()
colunas_correlacionadas = correlacoes[correlacoes > 0.3].index.drop('certified', errors='ignore')

X = df_scaled[colunas_correlacionadas]
y = df_scaled['certified'] # 1 = certificado (não precisa de tutoria), 0 = precisa

# 6. DIVISÃO TREINO E TESTE
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 7. TREINAMENTO DO MODELO KNN
modelo_knn = KNeighborsClassifier(n_neighbors=5)
modelo_knn.fit(X_train, y_train)


# 8. AVALIAÇÃO DO MODELO
y_pred = modelo_knn.predict(X_test)

print("🔵 Avaliação do Modelo KNN:")
print("Acurácia:", accuracy_score(y_test, y_pred))
print("\nMatriz de Confusão:\n", confusion_matrix(y_test, y_pred))
print("\nRelatório de Classificação:\n", classification_report(y_test, y_pred))

# 9. VISUALIZAÇÃO DA MATRIZ DE CONFUSÃO
plt.figure(figsize=(6,4))
sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predito')
plt.ylabel('Real')
plt.title('Matriz de Confusão - KNN')
plt.show()

# 10. RECOMENDAÇÃO DE TUTORIA
df_resultados = X_test.copy()
df_resultados['precisa_tutoria'] = 1 - y_pred # 1 = precisa de tutoria
df_resultados['recomendado'] = df_resultados['precisa_tutoria'].apply(lambda x: "Sim" if x == 1 else "Não")

print("🟡 Alunos recomendados para tutoria (amostra):")
display(df_resultados[df_resultados['recomendado'] == 'Sim'].head(10))
```

AVALIAÇÃO E RECOMENDAÇÃO

- Acurácia do modelo: 98,58%
- Matriz de confusão:
- VP: 2.676 | VN: 123.736
- FN: 917 (área para melhoria)
- Limitação: Recall da classe "precisa de tutoria" ainda pode ser melhorado.
- Saída final: Geração de lista de alunos recomendados para tutoria (recomendado = Sim).
- Aplicação prática: Direcionamento eficiente de recursos de apoio educacional.

🔔 Alunos recomendados para tutoria (amostra):

	explored	nevents	ndays_act	nplay_video	nchapters	precisa_tutoria	recomendado
396953	0.0	0.000010	0.000000	0.001156	0.056052	1.0	Sim
218231	0.0	0.000197	0.014706	0.000020	0.000000	1.0	Sim
71915	0.0	0.002174	0.023089	0.001156	0.021277	1.0	Sim
358287	0.0	0.000192	0.019608	0.000102	0.021277	1.0	Sim
96434	0.0	0.002174	0.023089	0.001156	0.042553	1.0	Sim
130620	0.0	0.002174	0.083333	0.001156	0.056052	1.0	Sim
61073	0.0	0.002174	0.023089	0.001156	0.056052	1.0	Sim
214626	0.0	0.001487	0.024510	0.001156	0.191489	1.0	Sim
493147	0.0	0.002174	0.000000	0.001156	0.056052	1.0	Sim
622284	0.0	0.000000	0.000000	0.001156	0.056052	1.0	Sim



CONCLUSÃO – MODELO DE RECOMENDAÇÃO ACADÊMICA

- O modelo KNN alcançou alta acurácia (98,58%), demonstrando eficácia na classificação de alunos com risco de não certificação.
- Etapas fundamentais: normalização dos dados, seleção de variáveis relevantes e divisão estratégica dos dados.
- Ponto de atenção: desempenho inferior na classe minoritária (alunos que precisam de tutoria), com recall de 74%.
- Próximos passos: explorar algoritmos mais robustos para dados desbalanceados (ex: Random Forest, XGBoost, SMOTE).
- Aplicabilidade prática: ferramenta automatizada que apoia a tutoria personalizada, reduz a evasão e fortalece a educação online.
- Impacto educacional: avanço no uso da IA para uma educação mais inclusiva, proativa e orientada por dados.




CONCLUSÃO GERAL

Engajamento como Fator-Chave para o Sucesso:

- Atividades como `nchapters`, `nplay_video` e `ndays_act` mostraram forte correlação com certificação.
- Alunos certificados participaram ativamente e permaneceram mais tempo engajados no curso.
- Participação em fóruns foi baixa no geral, mas mais frequente entre alunos que se certificaram.

Desafios Identificados:

- Baixa taxa de certificação (2,8%), indicando evasão significativa.
- Alunos não certificados tiveram menos dias ativos (mediana de 25 vs. 100).
- Necessidade de estratégias de retenção mais eficazes nos primeiros meses.
-



CONCLUSÃO GERAL – VARIÁVEIS, LIMITAÇÕES E INSIGHTS FINAIS

Impacto de Variáveis Demográficas:

- Faixa etária predominante: 22 a 31 anos, com possíveis demandas específicas.
- Estados Unidos com maior representatividade entre os alunos.
- Predominância masculina, possível viés de gênero nos cursos analisados.

Limitações e Considerações:

- Alta taxa de dados faltantes em variáveis-chave (ex: nplay_video, LoE_DI).
- Correlação forte entre explored e certified (0.68), e entre ndays_act e nevents (0.84).
- Variáveis como YoB e nforum_posts tiveram baixo impacto isolado.

Conclusão Geral:

- A análise revelou padrões críticos para personalizar tutoria e reduzir evasão.
 - A combinação de dados comportamentais e algoritmos preditivos oferece grande potencial para intervenções educacionais proativas.
- 



CONCLUSÃO E TRABALHOS FUTUROS

Intervenções Baseadas em Engajamento:

- Alertas Automáticos: Notificações na primeira semana para alunos com baixa atividade.
- Gamificação: Uso de metas, rankings e medalhas para incentivar `nchapters` e `ndays_act`.

Personalização do Suporte:

- Segmentação por Perfil: Trilhas de aprendizagem adaptadas por idade, país e escolaridade.
- Mentoria Proativa: Tutores para alunos com menos de 25 dias ativos — grupo com maior risco de evasão.
-



CONCLUSÃO E TRABALHOS FUTUROS

Melhoria na Coleta e Análise de Dados:

- Redução de Dados Faltantes: Priorizar variáveis críticas como `nplay_video` e `LoE_DI`.
- Dados Qualitativos: Aplicar pesquisas de satisfação e autoavaliação para entender motivações.

Perspectivas Futuras:

- Modelos Preditivos: Estimar risco de evasão com machine learning.
- Análise Temporal: Identificar padrões sazonais para ajustar prazos e estratégias.

Conclusão:

- Propostas baseadas em evidências, com potencial para intervenções personalizadas e escaláveis.
- Contribuição significativa para reduzir evasão e melhorar o desempenho em ambientes online.



ACESSO AO REPOSITÓRIO NO GITHUB:



ACESSO AO GOOGLE COLAB (AED):



**ACESSO A APRESENTAÇÃO
(YOUTUBE):**





SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

Grupo 14: Rayan Crhistofer, Amanda Schwantes, Thábata Cristina e Tiago Riuji