

UNIVERSIDADE PRESBITERIANA MACKENZIE

RAYAN CRHISTOFER GOMES DA SILVA, THÁBATA CRISTINA SEIXAS BALBINO,
AMANDA SCHWANTES MAIA, TIAGO RIUJI UEDA.

SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE
ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

SÃO PAULO

2025

SUMÁRIO

1 INTRODUÇÃO.....	3
1.1 Motivação.....	4
1.2 Justificativa.....	4
2 OBJETIVO GERAL.....	5
2.1 Objetivos específicos.....	5
3 REFERENCIAL TEÓRICO.....	6
3.1 Sistemas de recomendação na educação.....	6
3.2 Modelos de aprendizado de máquina aplicados.....	7
3.3 Engajamento e retenção em cursos online.....	7
3.4 Desafios na implementação de sistemas de recomendação educacional.....	8
3.5 Considerações finais.....	8
4 GRUPO DE TRABALHO.....	8
5 APRESENTAÇÃO DO DATASET.....	9
5.1 Descrição Geral.....	9
5.2 Estrutura do Dataset.....	10
5.3 Objetivos do Dataset.....	10
5.4 Aplicações do Dataset.....	11
5.5 Importância para sistemas de recomendação.....	11
6 BIBLIOTECAS PYTHON.....	12
7 CRONOGRAMA.....	13
8 REPOSITÓRIO GITHUB.....	14
9 REFERENCIAS BIBLIOGRAFICAS.....	15

1. INTRODUÇÃO

O ensino a distância (EaD) tem crescido exponencialmente nos últimos anos, oferecendo oportunidades educacionais para um público mais amplo e diversificado. Entre 2011 e 2021, o número de ingressantes em cursos superiores na modalidade EaD aumentou 474% [1]. No entanto, esse crescimento também trouxe desafios significativos, como a necessidade de garantir a qualidade do ensino e o engajamento dos estudantes. A taxa de evasão no ensino superior brasileiro, por exemplo, atinge cerca de 60%, sendo de 58% nos cursos presenciais e 59% na modalidade EaD [2].

Durante a pandemia de COVID-19, a transição abrupta para o ensino remoto afetou ainda mais o desempenho dos alunos. Um estudo revelou que quase um terço (30,5%) dos estudantes percebeu uma piora no rendimento acadêmico com a adoção do ensino a distância, citando fatores como desmotivação e dificuldades de adaptação [3]. Além disso, a desigualdade no acesso à internet representa um obstáculo significativo para muitos alunos, com cerca de 46 milhões de brasileiros sem conexão adequada [4]. Outro fator que impacta o desempenho acadêmico é o uso excessivo de redes sociais, uma vez que 62% dos alunos acreditam que o tempo dedicado a essas plataformas prejudica seus estudos [5].

Diante desse cenário, este projeto propõe o desenvolvimento de um **sistema inteligente para suporte acadêmico**, baseado em um modelo de recomendação de alunos que necessitam de maior apoio acadêmico. O sistema visa auxiliar professores, tutores e monitores na tomada de decisões sobre intervenções pedagógicas, evitando a evasão e promovendo uma educação de qualidade. Para isso, utilizamos um conjunto de dados detalhado sobre o engajamento de estudantes em cursos online, denominado *Online Course Student Engagement Metrics* [6].

Esse dataset contém informações como status de registro do aluno, atividades realizadas no curso, participação em fóruns, notas obtidas e nível de escolaridade. Com base nesses dados, aplicaremos técnicas de ciência de dados e aprendizado de máquina para identificar padrões de comportamento e prever quais alunos têm maior probabilidade de abandonar o curso ou apresentar baixo desempenho.

O desenvolvimento deste projeto está alinhado com os Objetivos de Desenvolvimento Sustentável (ODS) da ONU, especificamente com o ODS 4 – **Educação de Qualidade**. Ao proporcionar um sistema de recomendação que identifica alunos em risco e facilita ações corretivas, esperamos contribuir para a redução da evasão e para a melhoria do aprendizado no ensino online.

1.1 MOTIVAÇÃO

O avanço da tecnologia tem proporcionado novas oportunidades para a educação, permitindo que um número crescente de pessoas tenha acesso ao conhecimento por meio de plataformas online. No entanto, um dos principais desafios desse modelo é garantir que os alunos permaneçam engajados e concluam os cursos, uma vez que a falta de acompanhamento individualizado pode levar à evasão.

A motivação para este projeto surge da necessidade de tornar a educação online mais eficiente e acessível, utilizando técnicas de Ciência de Dados para oferecer suporte direcionado aos alunos. Ao criar um sistema de recomendação de tutoria, espera-se contribuir para um aprendizado mais

personalizado, incentivando a permanência dos estudantes e promovendo uma educação de qualidade, alinhada aos Objetivos de Desenvolvimento Sustentável (ODS).

Além disso, o projeto permite explorar na prática conceitos de aprendizado de máquina e análise de dados, proporcionando uma aplicação real das técnicas estudadas no curso de Ciência de Dados. Essa experiência agrega valor tanto para o desenvolvimento acadêmico quanto para o aprimoramento profissional, demonstrando o impacto positivo da tecnologia na educação.

1.2 JUSTIFICATIVA

A educação a distância tem se tornado cada vez mais relevante, especialmente com o crescimento das plataformas de ensino online. No entanto, um dos principais desafios desse modelo é a taxa de evasão dos alunos, muitas vezes causada pela falta de acompanhamento adequado e dificuldades no aprendizado.

Para mitigar esse problema, um sistema de recomendação de tutores pode auxiliar na identificação de alunos que necessitam de suporte adicional, melhorando seu desempenho acadêmico e aumentando a taxa de conclusão dos cursos.

Este projeto se justifica pela importância de garantir uma educação de qualidade (ODS 4), utilizando técnicas de Ciência de Dados para personalizar o aprendizado e proporcionar uma experiência mais eficiente e inclusiva para os estudantes.

2. OBJETIVO GERAL

Desenvolver um sistema de recomendação que identifique alunos com dificuldades em cursos online e sugira tutores adequados para auxiliá-los, promovendo uma experiência educacional mais personalizada e eficiente.

2.1 OBJETIVOS ESPECÍFICOS

- **Realizar uma análise exploratória dos dados** para compreender padrões de engajamento e desempenho dos alunos em cursos online.

- **Definir e aplicar métodos de aprendizado de máquina** para prever a necessidade de tutoria com base no histórico de interação dos alunos.
- **Avaliar a eficácia do sistema de recomendação**, comparando diferentes abordagens e métricas de desempenho.
- **Desenvolver uma interface ou dashboard** para visualização das recomendações, facilitando a interpretação dos resultados pelos gestores educacionais.
- **Validar os resultados** por meio de testes e ajustes, garantindo que as recomendações sejam precisas e alinhadas às necessidades dos alunos.

3. REFERENCIAL TEÓRICO

O acesso à educação de qualidade é um dos pilares fundamentais para o desenvolvimento social e econômico, conforme estabelecido pelo Objetivo de Desenvolvimento Sustentável (ODS) 4 da Agenda 2030 da ONU. No contexto da educação online, um dos desafios enfrentados é a personalização do ensino para atender às necessidades individuais dos alunos. Sistemas de recomendação baseados em dados têm sido amplamente estudados como uma solução eficaz para melhorar o engajamento e a retenção dos estudantes (ROMERO; VENTURA, 2020).

3.1 Sistemas de recomendação na educação

Os sistemas de recomendação são amplamente utilizados para fornecer experiências personalizadas em diversas áreas, incluindo a educação. Segundo Ricci et al. (2015), tais sistemas utilizam técnicas de aprendizado de máquina e análise de dados para identificar padrões de comportamento e sugerir conteúdo relevante. Em ambientes de aprendizado online, esses sistemas podem recomendar cursos, materiais didáticos ou até mesmo tutores para auxiliar estudantes com dificuldades (BOGDANOV et al., 2019).

No contexto educacional, a recomendação personalizada permite uma abordagem adaptativa ao aprendizado, considerando o progresso individual de cada estudante. Estudos apontam que o uso dessas ferramentas contribui significativamente para o aumento da taxa de conclusão de cursos online e melhora a experiência do estudante (AL-SAMARRAIE; SAH; FAALY, 2020).

3.2 Modelos de aprendizado de máquina aplicados

Diferentes abordagens de aprendizado de máquina são empregadas para construir sistemas de recomendação, incluindo:

- **Filtragem Colaborativa:** Baseia-se na interação entre usuários para prever preferências futuras (SU; KONSTAN, 2009).
- **Filtragem Baseada em Conteúdo:** Utiliza atributos dos objetos recomendados para criar perfis personalizados (LÓPEZ-NICOLÁS et al., 2021).
- **Modelos Híbridos:** Combinam as duas abordagens anteriores para aumentar a precisão das recomendações (BURKE, 2002).

Estudos recentes indicam que modelos baseados em redes neurais e aprendizado profundo têm obtido desempenho superior na personalização do aprendizado (ZHANG et al., 2019). Esses modelos utilizam técnicas como redes neurais convolucionais (CNNs) e redes neurais recorrentes (RNNs) para capturar padrões de comportamento dos alunos e prever quais recursos educacionais podem ser mais relevantes para cada um.

3.3 Engajamento e Retenção em Cursos Online

A baixa retenção em plataformas de educação online é um problema recorrente. Segundo Kizilcec et al. (2017), alunos que recebem suporte direcionado e interação personalizada tendem a ter maior engajamento. Nesse sentido, a recomendação de tutores pode ser um fator determinante para o sucesso acadêmico, ao conectar estudantes que necessitam de apoio com mentores capacitados.

Fatores como feedback imediato, incentivo ao aprendizado autônomo e criação de comunidades de aprendizagem também impactam positivamente a permanência do aluno em cursos online (ANDERSON et al., 2020). O uso de algoritmos de recomendação não apenas melhora a experiência do estudante, mas também pode contribuir para a identificação precoce de alunos em risco de abandono.

3.4 Desafios na Implementação de Sistemas de Recomendação Educacional

A implementação de sistemas de recomendação na educação enfrenta desafios como:

- **Privacidade e Segurança dos Dados:** O uso de informações sensíveis de alunos levanta preocupações sobre proteção de dados e ética (DANKAR; ELMOLHIM, 2020).
- **Viés Algorítmico:** Modelos de recomendação podem reforçar desigualdades existentes ao sugerir conteúdos que favorecem certos grupos em detrimento de outros (GE et al., 2020).
- **Aceitação dos Usuários:** Professores e alunos podem ter resistência ao uso dessas tecnologias, exigindo estratégias eficazes de integração e treinamento (MARTIN et al., 2021).

3.5 Considerações Finais

A implementação de sistemas de recomendação na educação online apresenta um grande potencial para promover o aprendizado personalizado e melhorar a retenção estudantil. A utilização de técnicas avançadas de aprendizado de máquina e análise de dados permite otimizar esse processo, contribuindo diretamente para os objetivos do ODS 4.

4. GRUPO DE TRABALHO

Para a implementação deste projeto, a equipe foi organizada de forma a distribuir as responsabilidades de acordo com as habilidades e interesses dos integrantes. A divisão das tarefas foi estruturada para garantir a eficiência na coleta, processamento, modelagem e apresentação dos dados, além da documentação do projeto.

Divisão das responsabilidades:

- **Amanda** – Responsável pelo processo de **ETL (Extração, Transformação e Carga de Dados)**, incluindo limpeza, pré-processamento e estruturação dos dados para a fase de modelagem.
- **Thabata** – Responsável pela **estruturação do documento e desenvolvimento do dashboard**, garantindo a visualização dos resultados de forma clara e acessível.
- **Rayan** – Responsável pela implementação e avaliação do modelo de **Machine Learning**, escolhendo os algoritmos mais adequados e otimizando sua performance.
- **Tiago** – Responsável pelo **apoio ao código e documentação**, auxiliando na implementação das soluções técnicas e garantindo que o projeto esteja devidamente documentado.

Essa divisão permite uma abordagem colaborativa e eficiente, assegurando que todas as etapas do desenvolvimento do sistema de recomendação sejam devidamente executadas. Além disso, a comunicação entre os membros será essencial para a integração das partes e a entrega de um projeto coeso e bem estruturado.

5. APRESENTAÇÃO DO DATASET

O dataset "Online Course Student Engagement Metrics" fornece detalhes abrangentes sobre o envolvimento, comportamento, atividade e desempenho dos alunos referentes aos cursos on-line para os quais eles se inscreveram. Cada registro nesta coleta de dados corresponde à experiência de um aluno com um curso específico. Este conjunto de dados é utilizado para estudar as métricas de engajamento dos alunos e pode ser aplicado em sistemas de recomendação, com foco no aumento da retenção e personalização da experiência do aluno.

index	course_id	used_id	registered	viewed	explored	certified	final_cc_course_id	LoE_Dt	YoB	gender	grade	start_time_Dt	last_event_Dt	revents	nplays_act	nplay_video	nchapters	nforum_posts	roles	incom
0	Honesty/CB22x/2013_Spring	MHWPC130442623	1	0	0	0	United States					0	2012-12-19	2013-11-17	9.0				0	1.0
1	Honesty/CSS50x/2012	MHWPC130442623	1	1	0	0	United States					0	2012-10-15		9.0		1.0		0	1.0
2	Honesty/CB22x/2013_Spring	MHWPC130275857	1	0	0	0	United States					0	2013-02-08	2013-11-17	16.0				0	1.0
3	Honesty/CSS50x/2012	MHWPC130275857	1	0	0	0	United States					0	2012-09-17		16.0				0	1.0
4	Honesty/ER22x/2013_Spring	MHWPC130275857	1	0	0	0	United States					0	2012-12-19		16.0				0	1.0
5	Honesty/PH207x/2012_Fall	MHWPC130275857	1	1	1	0	United States					0	2012-09-17	2013-05-23 002.0	16.0	50.0	12.0		0	
6	Honesty/PH278x/2013_Spring	MHWPC130275857	1	0	0	0	United States					0	2013-02-08		16.0				0	1.0
7	Honesty/CB22x/2013_Spring	MHWPC130539455	1	1	0	0	France					0	2013-01-01	2013-05-14 42.0	6.0		3.0		0	
8	Honesty/CB22x/2013_Spring	MHWPC130088379	1	1	0	0	United States					0	2013-02-16	2013-03-17 70.0	3.0		3.0		0	
9	Honesty/CSS50x/2012	MHWPC130088379	1	1	0	0	United States					0	2012-10-20		12.0		3.0		0	1.0
10	Honesty/ER22x/2013_Spring	MHWPC130088379	1	1	0	0	United States					0	2013-02-23	2013-06-14 17.0	2.0		2.0		0	
11	Honesty/ER22x/2013_Spring	MHWPC130198098	1	1	0	0	United States					0	2013-06-17	2013-06-17 32.0	1.0		3.0		0	
12	Honesty/CB22x/2013_Spring	MHWPC130024894	1	1	0	0	United States		0.07			2013-01-24	2013-08-03 175.0		9.0		7.0		0	
13	Honesty/CSS50x/2012	MHWPC130024894	1	1	0	0	United States					0	2013-06-27		2.0		2.0		0	1.0
14	Honesty/ER22x/2013_Spring	MHWPC130024894	1	1	0	0	United States					0	2012-12-19	2013-08-17 78.0	5.0		4.0		0	
15	Honesty/PH207x/2012_Fall	MHWPC130024894	1	1	0	0	United States					0	2012-07-26	2013-01-16 75.0	14.0	5.0	2.0		0	
16	Honesty/PH278x/2013_Spring	MHWPC130024894	1	1	0	0	United States					0	2013-07-30	2013-08-27 11.0	2.0	2.0	1.0		0	
17	Honesty/CSS50x/2012	MHWPC130080986	1	1	0	0	United States					0	2012-10-15		11.0		1.0		0	1.0
18	Honesty/PH207x/2012_Fall	MHWPC130080986	1	1	0	0	United States					0	2012-10-25	2012-12-04 56.0	11.0	1.0	2.0	1		
19	Honesty/CSS50x/2012	MHWPC130063375	1	1	0	0	Unknown/Other					0	2012-10-19				1.0		0	1.0
20	Honesty/CSS50x/2012	MHWPC130094371	1	1	0	0	United States					0	2013-03-03	2013-03-03 7.0	1.0		2.0		0	
21	Honesty/CSS50x/2012	MHWPC130229084	1	1	0	0	Mexico					0	2012-10-15				1.0		0	1.0
22	Honesty/CSS50x/2012	MHWPC130300925	1	1	0	0	United States					0	2012-10-24		2.0		1.0		0	1.0
23	Honesty/ER22x/2013_Spring	MHWPC130300925	1	1	0	0	United States					0	2012-12-20	2013-05-18 15.0	2.0		2.0		0	
24	Honesty/CSS50x/2012	MHWPC130417650	1	1	0	0	Australia					0	2012-10-29	2013-03-04 1.0	1.0		2.0		0	
25	Honesty/CSS50x/2012	MHWPC130500580	1	0	0	0	United States					0	2012-09-04						0	
26	Honesty/CSS50x/2012	MHWPC130298257	1	0	0	0	United States					0	2012-09-05				3.0		0	1.0

Imagem 1: Apresentação do Dataset

5.1 Descrição Geral

O dataset contém **77 MB** de dados e é composto por informações relacionadas aos alunos e suas interações com os cursos online. O conjunto de dados tem como objetivo auxiliar na análise de como o engajamento de um aluno em cursos online pode ser medido e como essas métricas podem ser utilizadas para personalizar o ensino.

A principal variável no dataset é o **engajamento** dos alunos com os cursos, que é caracterizado por ações como visualizações de vídeos, participação em discussões, testes e completamento de atividades. Os dados incluem diferentes variáveis demográficas e de interação, que são fundamentais para criar perfis de engajamento e identificar padrões de comportamento dos estudantes.

5.2 Estrutura do Dataset

O dataset é composto por várias colunas, sendo as principais:

- **student_id**: Identificador único do aluno.
- **course_id**: Identificador único do curso em que o aluno está matriculado.
- **nplay_video**: Número de vezes que o aluno assistiu a vídeos no curso.
- **nquiz_attempts**: Número de tentativas de quizzes realizadas pelo aluno.
- **nforum_posts**: Número de postagens feitas pelo aluno em fóruns de discussão.
- **completion_flag**: Indicador de se o aluno completou ou não o curso.
- **incomplete_flag**: Indicador de se o aluno deixou o curso incompleto.
- **roles**: Indica o papel do aluno no curso (e.g., estudante, instrutor).

Além dessas colunas principais, o dataset contém diversas outras variáveis relacionadas à participação e ao progresso do aluno no curso.

5.3 Objetivo do Dataset

O objetivo principal deste dataset é entender o comportamento dos alunos dentro de um ambiente de aprendizado online, analisando aspectos como o tempo gasto em vídeos, a participação em discussões nos fóruns, e a realização de quizzes. Tais informações podem ser usadas para criar sistemas de recomendação, que podem sugerir conteúdo personalizado e interações para cada aluno, ajudando a melhorar a experiência de aprendizagem e aumentar a retenção dos estudantes.

5.4 Aplicações do Dataset

Este conjunto de dados pode ser utilizado em diversas áreas, como:

- **Recomendação de cursos:** A partir da análise do engajamento do aluno, é possível sugerir cursos mais adequados ao seu perfil.
- **Aprimoramento de estratégias de engajamento:** Identificação de alunos em risco de evasão e sugestões de intervenções, como tutorias ou lembretes.
- **Análise de impacto de atividades:** Verificação de como a participação em atividades (vídeos, quizzes, fóruns) influencia a conclusão do curso.

5.5 Importância para Sistemas de Recomendação

Este dataset é particularmente útil para a criação de **sistemas de recomendação** baseados em dados educacionais, como a recomendação de cursos, tutorias ou materiais de estudo, com base nas preferências e comportamentos do aluno. Além disso, o engajamento e o comportamento dos alunos são variáveis cruciais para o desenvolvimento de sistemas personalizados que melhor atendem às necessidades de cada estudante, promovendo um aprendizado mais eficaz.

6. BIBLIOTECAS PYTHON

Para o desenvolvimento do sistema de recomendação de tutores para alunos em cursos online, foram empregadas diversas bibliotecas da linguagem Python, cada uma selecionada por suas funcionalidades específicas que atendem às necessidades do projeto. A seguir, apresenta-se uma descrição sucinta de cada biblioteca:

1. **Pandas:** Utilizada para manipulação e análise de dados tabulares, permitindo a leitura, limpeza e transformação dos dados referentes aos alunos e cursos.
2. **NumPy:** Empregada para operações matemáticas e manipulação de arrays multidimensionais, facilitando cálculos eficientes necessários aos algoritmos de recomendação.
3. **Scikit-learn:** Fornece ferramentas para modelagem preditiva, incluindo algoritmos de aprendizado de máquina, métricas de avaliação e técnicas de pré-processamento de dados.
4. **Surprise:** Especializada na construção e análise de sistemas de recomendação baseados em dados de avaliações explícitas, oferecendo implementações de diversos algoritmos colaborativos.
5. **RecBole:** Oferece uma estrutura unificada, abrangente e eficiente para desenvolver e reproduzir algoritmos de recomendação, suportando uma variedade de modelos e técnicas.
6. **Matplotlib e Seaborn:** Utilizadas para a visualização de dados, auxiliando na exploração e compreensão dos padrões de comportamento dos alunos por meio de gráficos e plots informativos.
7. **TensorFlow ou PyTorch:** Caso sejam empregados modelos de aprendizado profundo, essas bibliotecas fornecem a infraestrutura necessária para a construção e treinamento de redes neurais complexas.

7. CRONOGRAMA

Cronograma de Atividades - Projeto Aplicado III
--

ATIVIDADE	DATA PREVISTA DE CONCLUSÃO	RESPONSÁVEL	OBSERVAÇÃO	STATUS
Etapa 1	28/02/2025	EQUIPE		Concluído
Revisão da etapa 1	03/02/2025	Thábata e Tiago		Concluído
Etapa 2	01/04/2025	EQUIPE		Concluído
Revisão da etapa 2	25/03/2025	Rayan		Concluído
Etapa 3	01/05/2025			
Revisão da etapa 3	25/04/2025			
Etapa 4	30/05/2025			
Revisão da etapa 4	25/05/2025			

8. REPOSITÓRIO GITHUB

Todos os arquivos e dados, como o dataset, análise de dados exploratória com Python (Google Colab), Modelo de aprendizado de máquina (Google Colab) e o Storytelling utilizados neste trabalho serão armazenados no [GitHub](#) [7].

9. REFERÊNCIAS BIBLIOGRÁFICAS

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). Ensino a distância cresce 474% em uma década. Brasília, 2022. Disponível em: <https://www.gov.br/inep/pt-br/assuntos/noticias/censo-da-educacao-superior/ensino-a-distancia-cresce-474-em-uma-decada>. Acesso em: 26 fev. 2025.

FUNDAÇÃO DE APOIO À TECNOLOGIA (FAT). Cenário de evasão do ensino superior derruba mito contra educação a distância. São Paulo, 2023. Disponível em: <https://fundacaofat.org.br/cenario-de-evasao-do-ensino-superior-derruba-mito-contr-educacao-a-distancia/>. Acesso em: 26 fev. 2025.

UNIVERSIDADE DO PORTO. Desempenho escolar de quase um terço dos alunos piorou com ensino a distância. Porto, 2022. Disponível em: <https://noticias.up.pt/2022/04/19/desempenho-escolar-de-quase-um-terco-dos-alunos-piorou-com-ensino-a-distancia/>. Acesso em: 26 fev. 2025.

CONFEDERAÇÃO NACIONAL DOS TRABALHADORES EM EDUCAÇÃO (CNTE). Pandemia ampliou desigualdade no ensino, evasão escolar e perda de aprendizagem. Brasília, 2023. Disponível em: <https://cnte.org.br/noticias/pandemia-ampliou-desigualdade-no-ensino-evasao-escolar-e-perda-de-aprendizagem-17ff>. Acesso em: 26 fev. 2025.

INSTITUTO FEDERAL FLUMINENSE (IFF). Redes sociais atrapalham desenvolvimento de alunos, diz pesquisa. Campos dos Goytacazes, 2022. Disponível em: <https://portal1.iff.edu.br/nossos-campi/campos-centro/noticias/redes-sociais-atrapalham-desenvolvimento-de-alunos-diz-pesquisa>. Acesso em: 26 fev. 2025.

KAGGLE. Online Course Student Engagement Metrics. Disponível em: <https://www.kaggle.com/datasets/thedevastator/online-course-student-engagement-metrics>. Acesso em: 24 fev. 2025.

SILVA, Rayan Crhistofer Gomes da. *Sistema inteligente para suporte acadêmico: recomendação de alunos para tutoria baseado em dados de cursos online*. 2025. Disponível em: https://github.com/RayanCrhistofer/SISTEMA-INTELIGENTE-PARA-SUPORTE-ACAD-MICO-RECOMENDA-O-DE-ALUNOS-PARA-TUTORIA---PRO_APL_3-MACK. Acesso em: 27 fev. 2025.

AL-SAMARRAIE, H.; SAH, A. A. M.; FAALY, T. M. "Personalized learning analytics in online learning environments: A systematic review and future directions". *Computers & Education*, v. 154, p. 103878, 2020.

- ANDERSON, T.; GARRISON, D. R.; ARCHER, W. "The community of inquiry framework: Research and practice in online learning". *The Internet and Higher Education*, v. 45, p. 100763, 2020.
- BOGDANOV, E.; ULLRICH, C.; KOPER, R.; BRUSILOVSKY, P. "Recommendations in online learning environments: Systematic review and research directions". *Educational Technology & Society*, v. 22, n. 3, p. 56-72, 2019.
- BURKE, R. "Hybrid recommender systems: Survey and experiments". *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331-370, 2002.
- DANKAR, F. K.; ELMOLHIM, M. "Privacy-preserving educational data mining: A survey of methods and trends". *Educational Technology Research and Development*, v. 68, n. 2, p. 1-20, 2020.
- GE, Y.; JIANG, H.; LEE, D. "Bias in recommendation systems: Challenges and solutions". *ACM Transactions on Computer-Human Interaction*, v. 27, n. 4, p. 1-23, 2020.
- KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. "Deconstructing disengagement: Analyzing learner subpopulations in massive open online courses". *Learning Analytics & Knowledge*, p. 170-179, 2017.
- LÓPEZ-NICOLÁS, G.; SANTOS, M. P.; RAMOS, C. "Content-based filtering in educational recommender systems: Recent advances and challenges". *Journal of Educational Computing Research*, v. 59, n. 6, p. 1079-1100, 2021.
- RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. *Recommender Systems Handbook*. Springer, 2015.
- MARTIN, F.; SUN, T.; WESTINE, C. D. "Examining faculty readiness for online teaching: A systematic review". *Distance Education*, v. 42, n. 1, p. 5-29, 2021.
- ROMERO, C.; VENTURA, S. "Educational data mining and learning analytics: A survey of research trends, techniques and applications". *Journal of Artificial Intelligence in Education*, v. 30, n. 1, p. 3-36, 2020.
- SU, X.; KONSTAN, J. A. "A survey of collaborative filtering techniques". *ACM Transactions on Computer-Human Interaction*, v. 22, n. 1, p. 5-29, 2009.
- ZHANG, S.; YAO, L.; SUN, A.; TAY, Y. "Deep learning based recommender system: A survey and new perspectives". *ACM Computing Surveys*, v. 52, n. 1, p. 1-38, 2019.