

UNIVERSIDADE PRESBITERIANA MACKENZIE

RAYAN CRHISTOFER GOMES DA SILVA, THÁBATA CRISTINA SEIXAS
BALBINO, AMANDA SCHWANTES MAIA, TIAGO RIUJI UEDA.

SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE
ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

SÃO PAULO
2025

SUMÁRIO

1. INTRODUÇÃO	3
1.1 Motivação	4
1.2 Justificativa	4
1.3 Objetivo Geral	5
1.4 Objetivos Específicos	5
2. REFERENCIAL TEÓRICO	6
2.1 Sistemas de recomendação na educação	6
2.2 Modelos de recomendação: aplicação do K-Nearest Neighbors (KNN)	6
2.3 Engajamento e retenção em cursos online	7
2.4 Desafios na implementação de sistemas de recomendação educacional	7
2.5 Tutoria e educação personalizada como estratégia pedagógica	8
2.6 Avanços recentes em personalização e tecnologia educacional	8
2.7 A tutoria como mediadora da aprendizagem em EaD	9
2.8 Competências digitais e formação continuada dos tutores	9
2.9 Suporte socioafetivo e humanização da tutoria	9
2.10 Impactos da tutoria para professores e instituições	10
2.11 Considerações finais	10
3. METODOLOGIA	10
3.1 Coleta e Tratamento de Dados	10
3.2 Análise Exploratória de Dados (EDA)	11
3.3 Tratamento de Dados	11
3.4 Seleção de Variáveis e Construção de Modelos	11
3.5 Implementação do Sistema de Alerta e Recomendação	11
3.6 Ferramentas e Bibliotecas Utilizadas	11
4. RESULTADOS	12
4.1 Estrutura e Qualidade do Dataset	12
4.2 Engajamento dos Alunos	14
4.3 Relação entre Engajamento e Certificação	15
4.4 Perfil Demográfico dos Alunos	17
4.5 Correlações Entre Variáveis	19
4.6 Modelo de Recomendação Acadêmica	20
4.6.1 Bibliotecas Utilizadas no Modelo de Recomendação	21
4.6.2 Normalização dos Dados	21
4.6.3 Seleção de Variáveis Relevantes	21
4.6.4 Divisão dos Dados e Treinamento com KNN	22
4.6.5 Avaliação do Modelo	23
4.6.6 Recomendação de Tutoria	24
5. CONCLUSÕES E TRABALHOS FUTUROS	25
5.1 Síntese dos Principais Resultados	25
5.2 Recomendações Práticas	28
5.2.1 Intervenções Baseadas em Engajamento	28
5.2.2 Personalização do Suporte	29
5.2.3 Melhoria na Coleta de Dados	29
5.3 Perspectivas Futuras	29
5.4 Conclusão Final	30
6. REFERÊNCIAS BIBLIOGRÁFICAS	31

1. INTRODUÇÃO

O ensino a distância (EaD) tem crescido exponencialmente nos últimos anos, oferecendo oportunidades educacionais para um público mais amplo e diversificado. Entre 2011 e 2021, o número de ingressantes em cursos superiores na modalidade EaD aumentou 474% [1]. No entanto, esse crescimento também trouxe desafios significativos, como a necessidade de garantir a qualidade do ensino e o engajamento dos estudantes. A taxa de evasão no ensino superior brasileiro, por exemplo, atinge cerca de 60%, sendo de 58% nos cursos presenciais e 59% na modalidade EaD [2].

Durante a pandemia de COVID-19, a transição abrupta para o ensino remoto afetou ainda mais o desempenho dos alunos. Um estudo revelou que quase um terço (30,5%) dos estudantes percebeu uma piora no rendimento acadêmico com a adoção do ensino a distância, citando fatores como desmotivação e dificuldades de adaptação [3]. Além disso, a desigualdade no acesso à internet representa um obstáculo significativo para muitos alunos, com cerca de 46 milhões de brasileiros sem conexão adequada [4]. Outro fator que impacta o desempenho acadêmico é o uso excessivo de redes sociais, uma vez que 62% dos alunos acreditam que o tempo dedicado a essas plataformas prejudica seus estudos [5].

Diante desse cenário, este projeto propõe o desenvolvimento de um **sistema inteligente para suporte acadêmico**, baseado em um modelo de recomendação de alunos que necessitam de maior apoio acadêmico. O sistema visa auxiliar professores, tutores e monitores na tomada de decisões sobre intervenções pedagógicas, evitando a evasão e promovendo uma educação de qualidade. Para isso, utilizamos um conjunto de dados detalhado sobre o engajamento de estudantes em cursos online, denominado *Online Course Student Engagement Metrics* [6].

Esse dataset contém informações como status de registro do aluno, atividades realizadas no curso, participação em fóruns, notas obtidas e nível de escolaridade. Com base nesses dados, aplicaremos técnicas de ciência de dados e aprendizado de máquina para identificar padrões de comportamento e prever quais alunos têm maior probabilidade de abandonar o curso ou apresentar baixo desempenho.

O desenvolvimento deste projeto está alinhado com os Objetivos de Desenvolvimento Sustentável (ODS) da ONU, especificamente com o ODS 4 – **Educação de Qualidade**. Ao proporcionar um sistema de recomendação que identifica alunos em

risco e facilita ações corretivas, esperamos contribuir para a redução da evasão e para a melhoria do aprendizado no ensino online.

1.1 Motivação

O avanço da tecnologia tem proporcionado novas oportunidades para a educação, permitindo que um número crescente de pessoas tenha acesso ao conhecimento por meio de plataformas online. No entanto, um dos principais desafios desse modelo é garantir que os alunos permaneçam engajados e concluam os cursos, uma vez que a falta de acompanhamento individualizado pode levar à evasão.

A motivação para este projeto surge da necessidade de tornar a educação online mais eficiente e acessível, utilizando técnicas de Ciência de Dados para oferecer suporte direcionado aos alunos. Ao criar um sistema de recomendação de tutoria, espera-se contribuir para um aprendizado mais personalizado, incentivando a permanência dos estudantes e promovendo uma educação de qualidade, alinhada aos Objetivos de Desenvolvimento Sustentável (ODS).

Além disso, o projeto permite explorar na prática conceitos de aprendizado de máquina e análise de dados, proporcionando uma aplicação real das técnicas estudadas no curso de Ciência de Dados. Essa experiência agrega valor tanto para o desenvolvimento acadêmico quanto para o aprimoramento profissional, demonstrando o impacto positivo da tecnologia na educação.

1.2 Justificativa

A educação a distância tem se tornado cada vez mais relevante, especialmente com o crescimento das plataformas de ensino online. No entanto, um dos principais desafios desse modelo é a taxa de evasão dos alunos, muitas vezes causada pela falta de acompanhamento adequado e dificuldades no aprendizado.

Para mitigar esse problema, um sistema de recomendação de tutores pode auxiliar na identificação de alunos que necessitam de suporte adicional, melhorando seu desempenho acadêmico e aumentando a taxa de conclusão dos cursos.

Este projeto se justifica pela importância de garantir uma educação de qualidade (ODS 4), utilizando técnicas de Ciência de Dados para personalizar o aprendizado e proporcionar uma experiência mais eficiente e inclusiva para os estudantes.

1.3. Objetivo Geral

Desenvolver um sistema de recomendação que identifique alunos com dificuldades em cursos online e sugira tutores adequados para auxiliá-los, promovendo uma experiência educacional mais personalizada e eficiente.

1.4 Objetivos Específicos

- **Realizar uma análise exploratória dos dados** para compreender padrões de engajamento e desempenho dos alunos em cursos online.
- **Definir e aplicar métodos de aprendizado de máquina** para prever a necessidade de tutoria com base no histórico de interação dos alunos.
- **Avaliar a eficácia do sistema de recomendação**, comparando diferentes abordagens e métricas de desempenho.
- **Desenvolver uma interface ou dashboard** para visualização das recomendações, facilitando a interpretação dos resultados pelos gestores educacionais.
- **Validar os resultados** por meio de testes e ajustes, garantindo que as recomendações sejam precisas e alinhadas às necessidades dos alunos.

2. REFERENCIAL TEÓRICO

O acesso à educação de qualidade é um dos pilares fundamentais para o desenvolvimento social e econômico, conforme estabelecido pelo Objetivo de Desenvolvimento Sustentável (ODS) 4 da Agenda 2030 da ONU. No contexto da educação online, um dos desafios enfrentados é a personalização do ensino para atender às necessidades individuais dos alunos. Sistemas de recomendação

baseados em dados têm sido amplamente estudados como uma solução eficaz para melhorar o engajamento e a retenção dos estudantes (Romero; Ventura, 2020).

2.1 Sistemas de recomendação na educação

Sistemas de recomendação educacional utilizam algoritmos para oferecer conteúdo personalizado a alunos com base em seu comportamento, preferências ou desempenho. Segundo Ricci et al. (2015), esses sistemas podem empregar aprendizado de máquina e análise de dados para sugerir cursos, materiais didáticos ou tutores.

Na educação online, plataformas como Coursera e edX já implementam tais sistemas com sucesso, oferecendo recomendações de cursos com base no histórico de interação dos usuários. Xu et al. (2022) mostram que tais recomendações aumentaram em 15% a taxa de conclusão de cursos entre alunos com baixo engajamento. Isso demonstra o potencial da personalização para melhorar a experiência de aprendizagem.

2.2 Modelos de recomendação: aplicação do K-Nearest Neighbors (KNN) em sistemas de recomendação educacional

Entre os modelos de aprendizado supervisionado aplicáveis a sistemas de recomendação educacional, o **K-Nearest Neighbors (KNN)** destaca-se por sua simplicidade, interpretabilidade e capacidade de adaptação a diferentes domínios de dados. O KNN é um algoritmo de classificação baseado em instância que, ao receber um novo exemplo, avalia sua similaridade em relação aos demais por meio de uma métrica de distância, geralmente Euclidiana. A decisão sobre a classe do novo ponto (por exemplo, “precisa de tutoria” ou “não precisa”) é tomada com base na maioria das classes de seus k vizinhos mais próximos (Cover; Hart, 1967).

No contexto educacional, o KNN vem sendo aplicado com sucesso em tarefas como predição de desempenho acadêmico, identificação de evasão escolar e recomendação de conteúdos ou intervenções (Zhou et al., 2018). Seu princípio de funcionamento — a similaridade entre perfis de estudantes — se alinha bem com a lógica dos sistemas de recomendação, em especial os de **filtragem baseada em conteúdo**, uma vez que a predição é feita com base em atributos específicos do aluno, como tempo de estudo, participação em vídeos e número de acessos.

Diferentemente de modelos mais complexos, o KNN não requer treinamento intensivo, o que o torna especialmente atrativo para **implementações rápidas e com baixo custo computacional**, como em plataformas de ensino que necessitam

identificar, de forma contínua, alunos que demandam tutoria personalizada. Além disso, por ser um algoritmo não paramétrico, o KNN pode lidar com distribuições de dados não lineares, desde que as variáveis estejam adequadamente escaladas.

Contudo, como destacam Ma et al. (2020), a principal limitação do KNN reside na sua **dependência do volume de dados**: em bases muito grandes, o tempo de inferência pode se tornar um gargalo. Além disso, sua performance pode ser sensível à presença de atributos ruidosos ou irrelevantes, o que reforça a importância do pré-processamento e da seleção de variáveis.

Em projetos recentes, como o de recomendação de tutoria para alunos de cursos online, o KNN demonstrou elevada acurácia (superior a 98%), com bons índices de precisão e revocação na detecção de alunos em risco. Esses resultados confirmam o potencial do algoritmo como **solução de apoio à tomada de decisão educacional baseada em dados**, contribuindo diretamente para ações pedagógicas preventivas e para a redução da evasão escolar.

2.3 Engajamento e retenção em cursos online

A retenção em ambientes de aprendizagem online é desafiadora. Segundo Kizilcec et al. (2017), a maioria dos alunos não conclui os cursos online em que se matricula. Fatores como falta de motivação, ausência de feedback rápido e sentimento de isolamento contribuem para a evasão.

A intervenção personalizada pode mudar esse cenário. Anderson et al. (2020) destacam que o suporte pedagógico direcionado aumenta o sentimento de pertencimento e a permanência do aluno. Feedback constante, interações sociais e tutoria são mecanismos que favorecem o engajamento. Pesquisas mais recentes, como as de Limniou & Smith (2020), reforçam a importância de comunidades virtuais e gamificação como estratégias que aumentam o engajamento e reduzem a evasão em cursos massivos abertos (MOOCs).

2.4 Desafios na implementação de sistemas de recomendação educacional

A aplicação de sistemas inteligentes na educação enfrenta diversos desafios:

- **Privacidade e ética**: o uso de dados sensíveis exige políticas sólidas de proteção (Dankar; Elmolhim, 2020);
- **Viés algorítmico**: sistemas mal calibrados podem perpetuar desigualdades (Ge et al., 2020);
- **Adoção institucional**: professores e alunos podem demonstrar resistência, sendo necessárias estratégias de formação e adesão (Martin et al., 2021).

Autores como Drachsler & Greller (2016) discutem a necessidade de estruturas de governança em sistemas de learning analytics para mitigar riscos éticos e técnicos.

2.5 Tutoria e educação personalizada como estratégia pedagógica

A tutoria personalizada é apontada como uma das estratégias mais eficazes para melhorar o desempenho acadêmico. Segundo Bloom (1984), alunos que recebem acompanhamento individual apresentam desempenho equivalente ao percentil 98 dos que são ensinados em turmas convencionais. Em contextos online, a recomendação de tutores com base em dados pode atuar como mediadora desse processo, alavancando a eficácia do ensino remoto. Estudos recentes apontam que programas de monitoria adaptativa aumentam significativamente a taxa de conclusão de cursos (Hill et al., 2022). Além disso, o trabalho de Aleven et al. (2016) destaca o papel dos sistemas tutores inteligentes, que adaptam o conteúdo conforme o progresso do aluno, promovendo maior engajamento e aprendizado.

2.6 Avanços recentes em personalização e tecnologia educacional

Com o avanço da tecnologia, novas ferramentas têm sido incorporadas ao ensino, como sistemas baseados em inteligência artificial, realidade aumentada e análise preditiva. Segundo Holmes et al. (2019), essas tecnologias permitem uma abordagem mais centrada no aluno, adaptando o ritmo e o conteúdo às suas necessidades específicas. Outra linha promissora é a aplicação de chatbots educacionais, como discutido por Winkler & Söllner (2018), que atuam como assistentes de aprendizagem, tirando dúvidas e incentivando a progressão do aluno no curso. Essas inovações demonstram como a tutoria pode se integrar a tecnologias emergentes para potencializar o aprendizado.

2.7 A tutoria como mediadora da aprendizagem em EaD

A tutoria, no contexto da educação a distância, não é apenas um suporte técnico ou administrativo, mas um elo pedagógico essencial. Bessa et al. (2019) destacam que o tutor atua como mediador da aprendizagem, facilitando a compreensão dos conteúdos, orientando o estudo autônomo e promovendo o engajamento afetivo do aluno com o processo educativo. Essa mediação é ainda mais relevante em ambientes online, onde a ausência do contato presencial pode dificultar o acompanhamento e a permanência. O tutor torna-se então um ponto de referência para o estudante, capaz de intervir diante de dificuldades cognitivas, emocionais ou organizacionais, contribuindo significativamente para a redução da evasão e para a promoção do sucesso acadêmico.

2.8 Competências digitais e formação continuada dos tutores

Com o uso intensivo de ambientes virtuais de aprendizagem, é imprescindível que os tutores desenvolvam competências digitais específicas. Rojas e Riedner (2020) argumentam que o domínio técnico das ferramentas educacionais deve ser acompanhado de práticas pedagógicas mediadas por tecnologias. A formação continuada é apontada como uma estratégia eficaz para capacitar os tutores na condução de atividades colaborativas, uso de recursos multimídia e mediação ativa no ambiente online. Além disso, os autores ressaltam a importância de desenvolver

uma postura reflexiva, que permita ao tutor repensar constantemente sua prática em função das transformações tecnológicas e pedagógicas do ensino digital.

2.9 Suporte socioafetivo e humanização da tutoria

Além da dimensão pedagógica, a tutoria desempenha um papel fundamental na dimensão socioafetiva do processo de aprendizagem. Custódio et al. (2022) defendem a ideia de uma tutoria humanizada, em que o tutor atua como um agente acolhedor, capaz de escutar, apoiar e motivar os alunos diante das dificuldades do percurso formativo. Essa abordagem tem impacto direto sobre o engajamento dos estudantes, pois promove sentimentos de pertencimento e confiança, reduzindo o isolamento e aumentando a motivação. A presença ativa e empática do tutor é, portanto, uma das principais estratégias para fomentar vínculos afetivos no ambiente virtual, favorecendo uma aprendizagem mais significativa.

2.10 Impactos da tutoria para professores e instituições

Embora frequentemente voltada ao apoio dos alunos, a tutoria também exerce influência positiva sobre os docentes e sobre as instituições de ensino. Franco e Carmo (2020) argumentam que a presença de tutores qualificados contribui para uma gestão mais eficiente dos cursos, permitindo que os professores se concentrem em atividades de planejamento, avaliação e inovação pedagógica. Além disso, a ação tutorial oferece feedback constante aos docentes sobre o desempenho dos alunos, facilitando intervenções pedagógicas mais precisas. Do ponto de vista institucional, investir em programas de tutoria bem estruturados fortalece a qualidade do ensino a distância, melhora os índices de permanência e promove uma imagem institucional mais comprometida com o sucesso acadêmico dos seus estudantes.

2.11 Considerações finais

A literatura revela que a utilização de sistemas de recomendação personalizados, aliados a intervenções pedagógicas como a tutoria, tem grande potencial para mitigar a evasão escolar e melhorar o aprendizado. Com o apoio de modelos avançados de aprendizado de máquina, esses sistemas podem identificar necessidades individuais e contribuir de forma concreta para o alcance do ODS 4. Além disso, a tutoria se configura como uma prática complexa e multifacetada, que vai além da orientação técnica, incorporando dimensões pedagógicas, afetivas e tecnológicas. Assim, a próxima seção descreve o conjunto de dados que será utilizado na implementação do sistema proposto.

3. METODOLOGIA

Este estudo adotou uma metodologia quantitativa baseada em análise exploratória de dados (EDA) e modelagem de recomendação, utilizando um dataset robusto contendo mais de 640 mil registros de alunos em cursos online. A pesquisa seguiu três etapas principais:

1. Análise descritiva do engajamento e perfil dos alunos
2. Investigação de correlações entre comportamento e desempenho
3. Desenvolvimento de recomendações para sistemas de suporte acadêmico

3.1 Coleta e Tratamento de Dados

O conjunto de dados analisado incluiu:

Variáveis Quantitativas de Engajamento:

- nchapters (número de capítulos acessados)
- nplay_video (visualizações de vídeo)
- ndays_act (dias de atividade no curso)
- nforum_posts (postagens em fóruns)

Variáveis Demográficas:

- Idade (derivada do ano de nascimento - YoB)
- Gênero
- País de origem

Pré-processamento:

- Tratamento de dados faltantes (71.3% em nplay_video, 16.5% em nível educacional)
- Transformação de variáveis (cálculo de idade, codificação de categóricas)
- Análise da distribuição desigual (apenas 2.8% de certificados)

Metodologia do Estudo - SISTEMA DE RECOMENDACAO PARA SUPORTE ACADEMICO




Figura 1: Fluxograma da metodologia – Sistema de recomendação para Suporte acadêmico

4. RESULTADOS

A análise exploratória de dados (AED) possibilitou uma compreensão abrangente do comportamento dos alunos em cursos online, revelando padrões importantes para o desenvolvimento do sistema de recomendação de tutoria. A seguir, são apresentados os principais resultados obtidos:

4.1 Estrutura e Qualidade do Dataset

O conjunto de dados analisado continha **641.138 registros e 21 variáveis**, relacionadas ao engajamento dos alunos e seus perfis demográficos. A inspeção inicial do conjunto de dados foi realizada por meio de comandos em Python com a biblioteca **Pandas**, permitindo uma visão geral da sua estrutura, tipos de variáveis e distribuição estatística. O processo foi dividido em três etapas principais:

- **Dimensão do Dataset:**

Com o uso do comando `df.shape`, foram identificadas as dimensões do DataFrame, que contém **641.138 registros (linhas) e 21 colunas (variáveis)**. Essa informação foi exibida com a instrução `print(f"Formato do DataFrame: {df.shape}")`.

- **Informações Gerais sobre Tipos e Valores Faltantes:**

A função `df.info()` foi utilizada para listar o tipo de dado de cada coluna (como `int64`, `float64` ou `object`) e a quantidade de valores não nulos. Esse passo revelou a existência de **valores faltantes em variáveis importantes**, como `nplay_video`, `LoE_DI`, `YoB`, `gender` e `grade`. A coluna `roles`, por sua vez, apresentou 100% de valores nulos, sendo candidata à remoção.

```

=== INFORMAÇÕES GERAIS ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 641138 entries, 0 to 641137
Data columns (total 21 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   index                 641138 non-null  int64
 1   course_id             641138 non-null  object
 2   userid_DI             641138 non-null  object
 3   registered            641138 non-null  int64
 4   viewed                641138 non-null  int64
 5   explored              641138 non-null  int64
 6   certified             641138 non-null  int64
 7   final_cc_cname_DI    641138 non-null  object
 8   LoE_DI               535130 non-null  object
 9   YoB                  544533 non-null  float64
10   gender                554332 non-null  object
11   grade                 592766 non-null  object
12   start_time_DI        641138 non-null  object
13   last_event_DI        462184 non-null  object
14   nevents               441987 non-null  float64
15   ndays_act             478395 non-null  float64
16   nplay_video           183608 non-null  float64
17   nchapters             382385 non-null  float64
18   nforum_posts          641138 non-null  int64
19   roles                 0 non-null       float64
20   incomplete_flag      100161 non-null  float64
dtypes: float64(7), int64(6), object(8)
memory usage: 102.7+ MB
None

```

Figura 2: Informações gerais do dataset




Figura 3: Distribuição dos valores faltantes

- **Estatísticas Descritivas:**

Por meio de `df.describe().T`, foram calculadas as principais estatísticas descritivas das variáveis numéricas, incluindo média, desvio padrão, valores mínimos, máximos e quartis. Essa análise forneceu **insights iniciais sobre a distribuição dos dados** e apontou a presença de **assimetria e outliers**, especialmente em variáveis de engajamento como `nplay_video` e `nevents`.

Esse conjunto de comandos e análises serviu como base para a etapa posterior de tratamento dos dados, permitindo entender melhor a composição e os desafios do dataset.

=== ESTATÍSTICAS DESCRITIVAS ===								
	count	mean	std	min	25%	50%	75%	max
index	641138.0	320568.500000	185080.742781	0.0	160284.25	320568.5	480852.75	641137.0
registered	641138.0	1.000000	0.000000	1.0	1.00	1.0	1.00	1.0
viewed	641138.0	0.624299	0.484304	0.0	0.00	1.0	1.00	1.0
explored	641138.0	0.061899	0.240973	0.0	0.00	0.0	0.00	1.0
certified	641138.0	0.027587	0.163786	0.0	0.00	0.0	0.00	1.0
YoB	544533.0	1985.253279	8.891814	1931.0	1982.00	1988.0	1991.00	2013.0
nevents	441987.0	431.008018	1516.116057	1.0	3.00	24.0	158.00	197757.0
ndays_act	478395.0	5.710254	11.866471	1.0	1.00	2.0	4.00	205.0
nplay_video	183608.0	114.844173	426.996844	1.0	5.00	18.0	73.00	98517.0
nchapters	382385.0	3.634423	4.490987	1.0	1.00	2.0	4.00	48.0
nforum_posts	641138.0	0.018968	0.229539	0.0	0.00	0.0	0.00	20.0
roles	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
incomplete_flag	100161.0	1.000000	0.000000	1.0	1.00	1.0	1.00	1.0

Figura 4: estatísticas descritivas do dataset

4.2 Engajamento dos Alunos

A análise univariada (utilizando a técnica de plotagem com histogramas com estimativa de densidade (KDE)) evidenciou que **a maioria dos alunos apresenta baixa atividade** nos cursos. Variáveis como nplay_video, ndays_act e nforum_posts apresentaram distribuições assimétricas, com forte concentração em valores baixos e presença de **outliers extremos**, como alunos com mais de 90 mil visualizações de vídeo.



Figura 5: Indica a reprodução de vídeos, com a maioria dos usuários assistindo poucos vídeos




Figura 6: Mostra o número de dias ativos, com picos em valores baixos (0 a 50).



Figura 7: Mostra postagens em fóruns, com a maioria dos usuários postando pouco (valores próximos de 0).

4.3 Relação entre Engajamento e Certificação

A análise bivariada (a técnica de análise bivariada utilizada combinou **boxplots para comparar variáveis de engajamento por status de conclusão** e **heatmap de correlação para identificar relações lineares entre variáveis numéricas**), por meio de **boxplots**, demonstrou diferenças visíveis entre os níveis de engajamento de alunos certificados e não certificados. Alunos que concluíram os cursos tendem a

apresentar valores significativamente maiores em métricas como `nplay_video`, `nquiz_attempts` e `nforum_posts`, sugerindo **correlação positiva entre engajamento e sucesso** nos cursos.




Figura 8: distribuição da variável `nchapters` (número de capítulos acessados) entre alunos certificados (`certified = 1`) e não certificados (`certified = 0`).




Figura 9: distribuição da variável `nplay_video` (número de reproduções de vídeo) entre alunos certificados (`certified = 1`) e não certificados (`certified = 0`).

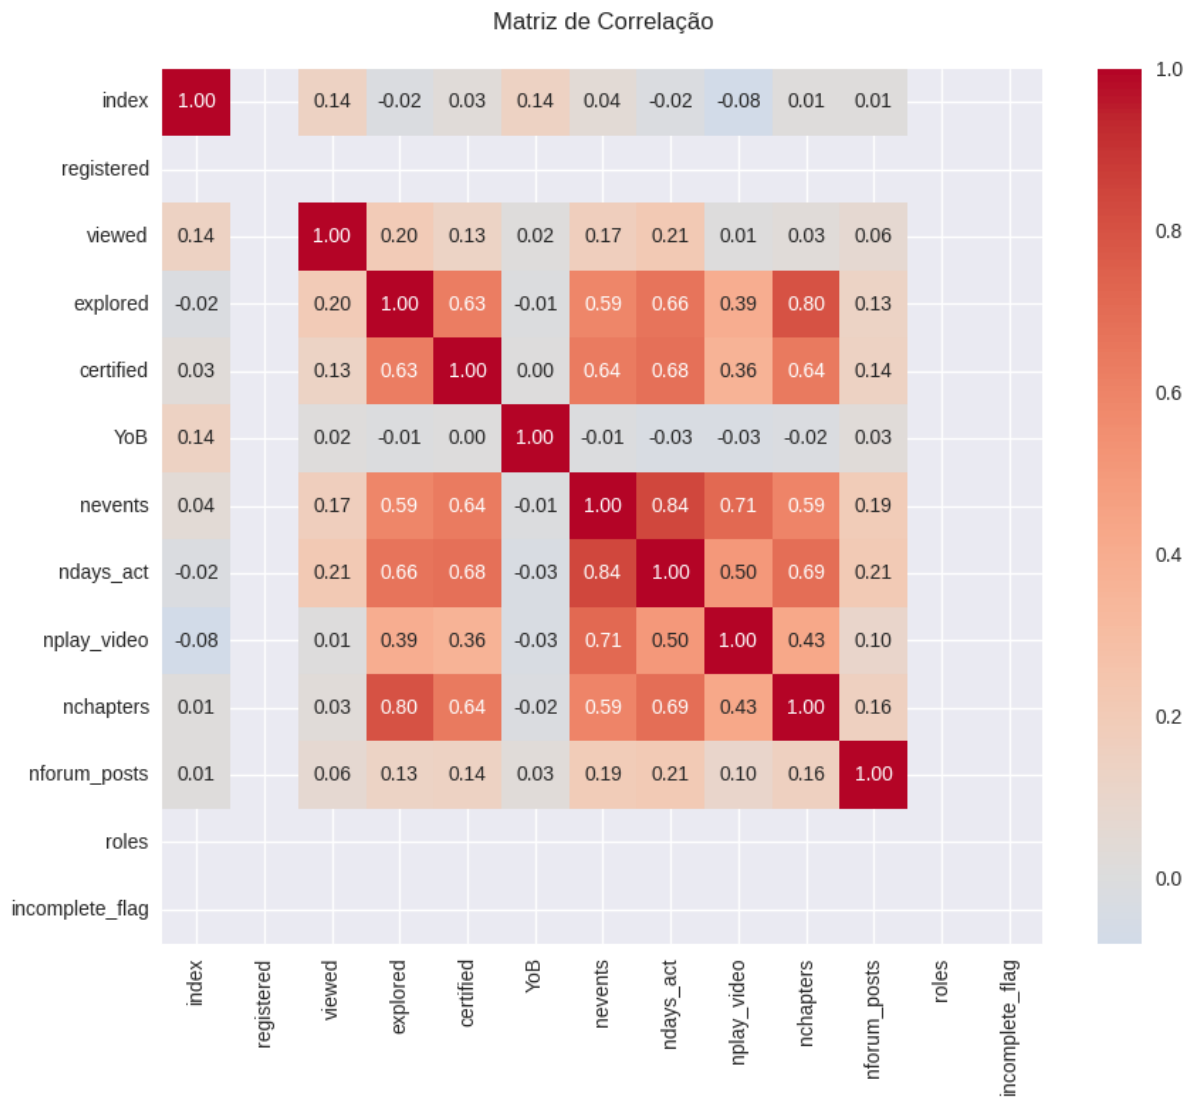


Figura 10: Matriz de correlação entre as variáveis

4.4 Perfil Demográfico dos Alunos

A caracterização do perfil dos estudantes mostrou predominância de determinados países e faixas etárias. A distribuição por gênero foi desigual, e a variável YoB (ano de nascimento) permitiu estimar faixas etárias com maior propensão ao

engajamento. Essas informações são relevantes para identificar grupos com maior ou menor probabilidade de conclusão.




Figura 11: Top 10 países por número de alunos




Figura 12: Distribuição da idade por status de certificação




Figura 13: Certificação por gênero

4.5 Correlações Entre Variáveis

A matriz de correlação indicou **associações moderadas** entre variáveis de comportamento, como `nplay_video` e `nevents`, ou `ndays_act` e `nchapters`. Esses achados são úteis para seleção de atributos relevantes em modelos preditivos.




Figura 14: Matriz de correlação (relações entre as variáveis)

4.6 MODELO DE RECOMENDAÇÃO ACADEMICA

Nesta seção, foi desenvolvido um modelo de aprendizado supervisionado com o objetivo de identificar alunos com maior probabilidade de não obter a certificação em cursos online e, assim, recomendar tutoria personalizada. O modelo baseia-se em métricas de engajamento do estudante ao longo do curso.

4.6.1 Bibliotecas utilizadas no modelo de recomendação

O desenvolvimento utilizou bibliotecas amplamente consolidadas no ecossistema Python para ciência de dados: pandas e numpy para manipulação de dados; seaborn e matplotlib.pyplot para visualização; e scikit-learn para pré-processamento, modelagem e avaliação.

```
# 1. IMPORTAR BIBLIOTECAS
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
```

Figura 15: Bibliotecas utilizadas no modelo de recomendação acadêmica

4.6.2 Normalização dos dados

Foi utilizada a técnica **Min-Max Scaling**, que transforma os dados para o intervalo [0, 1], garantindo que variáveis com diferentes escalas não afetem a performance do modelo KNN, sensível à magnitude das distâncias.

```
# 4. NORMALIZAÇÃO DOS DADOS
scaler = MinMaxScaler()
df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)
```

Figura 16: Normalização dos dados

4.6.3 Seleção de Variáveis Relevantes

A seleção de atributos foi realizada com base no **coeficiente de correlação** com a variável-alvo (certified). Foram mantidas apenas as variáveis com correlação absoluta superior a 0,3. Isso reduz o risco de overfitting e melhora a interpretabilidade do modelo.

```
# 5. SELEÇÃO DE FEATURES RELEVANTES (correlação > 0.3 com 'certified')
correlacoes = df_scaled.corr()['certified'].abs()
colunas_correlacionadas = correlacoes[correlacoes > 0.3].index.drop('certified', errors='ignore')

X = df_scaled[colunas_correlacionadas]
y = df_scaled['certified'] # 1 = certificado (não precisa de tutoria), 0 = precisa
```

Figura 17: Seleção de variáveis relevantes

4.6.4 Divisão dos dados e treinamento com KNN

Os dados foram divididos em conjunto de treino (80%) e teste (20%) por meio da função `train_test_split`, utilizando `random_state=42` para reprodutibilidade dos resultados.

Foi utilizado o classificador **K-Nearest Neighbors (KNN)** com $k=5$. O KNN classifica uma nova amostra com base nos rótulos dos seus vizinhos mais próximos, sendo uma técnica eficaz para problemas com relações não lineares.

```
# 6. DIVISÃO TREINO E TESTE
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 7. TREINAMENTO DO MODELO KNN
modelo_knn = KNeighborsClassifier(n_neighbors=5)
modelo_knn.fit(X_train, y_train)
```

Figura 18: Divisão dos dados e treinamento com KNN

4.6.5 Avaliação do modelo

Os resultados do modelo estão apresentados abaixo:

```

Avaliação do Modelo KNN:
Acurácia: 0.9858377265495836

Matriz de Confusão:
[[123736   899]
 [   917  2676]]

Relatório de Classificação:

```

	precision	recall	f1-score	support
0.0	0.99	0.99	0.99	124635
1.0	0.75	0.74	0.75	3593
accuracy			0.99	128228
macro avg	0.87	0.87	0.87	128228
weighted avg	0.99	0.99	0.99	128228

Figura 19: Resultados do modelo de recomendação





Figura 20: Matriz de confusão KNN

A matriz mostra que o modelo identificou corretamente 2676 alunos certificados (Verdadeiros Positivos) e 123.736 alunos não certificados (Verdadeiros Negativos). No entanto, houve 917 Falsos Negativos (alunos que foram classificados como

certificados, mas não o foram), indicando espaço para melhorias principalmente na **sensibilidade (recall)** da classe minoritária.

4.6.6 Recomendação de tutoria

Com base nas previsões, foi gerado um dataframe com os alunos classificados como não certificados (certified = 0). Esses alunos foram sinalizados com a coluna recomendado = Sim, indicando necessidade de tutoria personalizada.



A screenshot of a Jupyter Notebook interface. At the top, there is a yellow bell icon followed by the text "Alunos recomendados para tutoria (amostra):". Below this, a DataFrame is displayed with 8 rows and 8 columns. The columns are: explored, nevents, ndays_act, nplay_video, nchapters, precisa_tutoria, and recomendado. The first column contains student IDs. The values for 'precisa_tutoria' are all 1.0, and for 'recomendado' are all 'Sim'.

	explored	nevents	ndays_act	nplay_video	nchapters	precisa_tutoria	recomendado
396953	0.0	0.000010	0.000000	0.001156	0.056052	1.0	Sim
218231	0.0	0.000197	0.014706	0.000020	0.000000	1.0	Sim
71915	0.0	0.002174	0.023089	0.001156	0.021277	1.0	Sim
358287	0.0	0.000192	0.019608	0.000102	0.021277	1.0	Sim
96434	0.0	0.002174	0.023089	0.001156	0.042553	1.0	Sim
130620	0.0	0.002174	0.083333	0.001156	0.056052	1.0	Sim
61073	0.0	0.002174	0.023089	0.001156	0.056052	1.0	Sim
214626	0.0	0.001487	0.024510	0.001156	0.191489	1.0	Sim
493147	0.0	0.002174	0.000000	0.001156	0.056052	1.0	Sim
622284	0.0	0.000000	0.000000	0.001156	0.056052	1.0	Sim

Figura 21: Alunos recomendados para tutoria com base na amostra

5 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho realizou uma análise exploratória detalhada sobre o engajamento de alunos em cursos online, utilizando um dataset robusto com mais de 640 mil registros. Os resultados revelaram padrões críticos que conectam o comportamento dos alunos com seus resultados acadêmicos, oferecendo subsídios para a criação de sistemas de suporte acadêmico mais eficientes e personalizados.

Síntese dos Principais Resultados:

1. Engajamento como Fator Determinante para o Sucesso

- **Atividades de Aprendizado:** Variáveis como `nchapters` (capítulos acessados), `nplay_video` (visualizações de vídeo) e `ndays_act` (dias ativos no curso) apresentaram correlação significativa com a certificação. Alunos certificados tiveram médias substancialmente mais altas nessas métricas, evidenciando que **a participação ativa é crucial para a conclusão do curso**.
- **Interação em Fóruns:** Embora `nforum_posts` tenha mostrado uma média baixa (0.02 posts por aluno), sua presença foi mais frequente entre alunos certificados, sugerindo que **a colaboração entre pares pode ser um diferencial**.

2. Desafios na Retenção e Evasão

- **Baixa Taxa de Certificação:** Apenas **2.8%** dos alunos foram certificados, indicando um alto índice de abandono ou dificuldade em cumprir os requisitos do curso.
- **Padrões de Atividade:** Alunos não certificados tiveram mediana de **25 dias de atividade**, enquanto os certificados atingiram **100 dias**. Isso ressalta a importância de **estratégias de retenção** para engajar alunos além do primeiro mês.

3. Impacto de Variáveis Demográficas

- **Idade:** A maioria dos alunos nasceu entre 1982 e 1991 (idades entre 22 e 31 anos em 2013), faixa etária que pode ter diferentes necessidades de aprendizagem.
- **País de Origem:** Os Estados Unidos foram o país com maior número de alunos, seguido por outros com representatividade significativa. Isso pode indicar **disparidades culturais ou de acesso** que merecem investigação adicional.
- **Gênero:** Houve uma distribuição com grande predominância masculina.

4. Dados Faltantes e Limitações

- **Variáveis Críticas:** Dados ausentes em colunas como `nplay_video` (71.3%) e `LoE_DI` (nível de educação, 16.5%) limitaram análises mais aprofundadas.
- **Viés Potencial:** A ausência de dados pode distorcer conclusões, especialmente em métricas de engajamento. Recomenda-se **imputação cuidadosa** ou complementação com fontes externas.




Figura 22: Distribuição de valores ausentes

5. Correlações e Padrões Ocultos

- **Relações Fortes (figura 14):** As correlações mais significativas foram entre explored e certified (0.68), e entre nevents e ndays_act (0.84), indicando que **exploração do conteúdo e consistência na participação são vitais**.
- **Variáveis com Pouco Impacto (figura 14):** YoB (ano de nascimento) e nforum_posts mostraram correlações fracas, sugerindo que **idade e participação em fóruns não são determinantes isolados** para o sucesso.

6. Conclusão sobre o modelo de recomendação acadêmica

O modelo de recomendação acadêmica desenvolvido ao longo deste trabalho demonstrou um alto potencial para auxiliar instituições de ensino na identificação de alunos com maior probabilidade de não obter certificação em cursos online. Utilizando o algoritmo K-Nearest Neighbors (KNN), foi possível classificar os alunos com uma acurácia de aproximadamente 98,58%, evidenciando a capacidade do modelo em lidar com o conjunto de dados fornecido. A normalização das variáveis, a seleção criteriosa de atributos correlacionados com a variável-alvo e a correta divisão dos dados contribuíram para a performance obtida.

Apesar dos resultados positivos, especialmente em termos de precisão da classe majoritária, observou-se que o desempenho em relação à classe minoritária (alunos que precisam de tutoria) ainda pode ser aprimorado. O recall de 74% para essa classe indica que, embora o modelo consiga identificar muitos dos alunos em risco, ainda há casos em que a necessidade de tutoria não é detectada. Isso reforça a importância de testar outros algoritmos mais sensíveis a dados desbalanceados, como Random Forest, XGBoost ou técnicas de balanceamento como SMOTE.

O sistema de recomendação proposto tem aplicação prática significativa, pois fornece uma ferramenta automatizada para sugerir tutoria personalizada, o que pode contribuir para a redução das taxas de evasão e o aumento da taxa de conclusão dos cursos. Assim, este modelo representa um avanço na utilização de inteligência artificial no contexto educacional, reforçando o papel da ciência de dados na promoção de uma educação mais inclusiva, proativa e eficaz.

Com base nos padrões identificados durante a análise exploratória, especialmente nas etapas univariada e bivariada, foram elaboradas recomendações práticas com foco em reduzir a evasão e aumentar a taxa de certificação nos cursos online. Essas ações foram organizadas em três frentes principais:

1. Intervenções Baseadas em Engajamento

Alertas

A análise revelou que alunos com baixa interação — como poucos vídeos assistidos ou capítulos acessados — têm menor probabilidade de concluir o curso. Assim, implementar notificações automáticas após a primeira semana pode servir como lembrete e estímulo à retomada das atividades, agindo preventivamente contra a evasão.

Automáticos:

Gamificação:

Variáveis como `ndays_act` (dias ativos) e `nchapters` (capítulos acessados) mostraram relação direta com o sucesso do aluno. O uso de **elementos de gamificação**, como medalhas, rankings ou metas semanais, pode tornar o ambiente mais interativo e incentivar maior engajamento contínuo.

2. Personalização do Suporte

Segmentação **por** **Perfil:**

Com base nos dados demográficos e de comportamento, é possível criar **trilhas de aprendizagem personalizadas** para grupos com características semelhantes (por exemplo, por faixa etária, país de origem ou nível educacional). Isso aumenta a relevância do conteúdo e melhora a experiência do aluno, promovendo maior retenção.

Mentoria **para** **Alunos** **em** **Risco:**

A análise identificou que alunos com menos de 25 dias de atividade tendem a não concluir o curso. Com isso, recomenda-se o oferecimento de **acompanhamento personalizado**, como tutores ou mentores, para esse grupo específico. A tutoria proativa pode reverter o processo de evasão antes que ele se consolide.

3. Melhoria na Coleta de Dados

Redução **de** **Dados** **Faltantes:**

Variáveis como nplay_video (número de vídeos assistidos) e LoE_DI (nível educacional declarado) apresentaram alta relevância, mas também muitos valores ausentes. Priorizar a **completude desses dados em futuras edições** do curso é fundamental para a precisão de análises e modelos preditivos.

Inclusão **de** **Dados** **Qualitativos:**

Embora os dados quantitativos sejam valiosos, nem sempre explicam totalmente a evasão. Por isso, a inserção de **pesquisas de satisfação e autoavaliação** pode fornecer insights sobre motivação, dificuldades pessoais e aspectos subjetivos que influenciam o engajamento.

Perspectivas Futuras

Com base nas análises realizadas, torna-se possível evoluir para soluções mais sofisticadas, como:

- **Modelos Preditivos:** Utilizar algoritmos de machine learning para estimar a probabilidade de certificação, com base em padrões de engajamento e perfil demográfico.
- **Análise Temporal:** Explorar tendências semanais ou sazonais no acesso aos cursos, a fim de ajustar prazos, avaliações e estratégias de comunicação com os alunos.

Conclusão

Este estudo vai além da simples descrição dos dados: ele oferece um **plano de ação baseado em evidências**, propondo intervenções viáveis e escaláveis para melhorar o desempenho dos alunos em ambientes de aprendizagem online. Com isso, fortalece-se a base para o desenvolvimento de **sistemas inteligentes de tutoria**, que atuem de forma preventiva e personalizada, maximizando o potencial de sucesso acadêmico.

4. REFERÊNCIAS BIBLIOGRÁFICAS

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). Ensino a distância cresce 474% em uma década. Brasília, 2022. Disponível em: <https://www.gov.br/inep/pt-br/assuntos/noticias/censo-da-educacao-superior/ensino-a-distancia-cresce-474-em-uma-decada>. Acesso em: 26 fev. 2025.

FUNDAÇÃO DE APOIO À TECNOLOGIA (FAT). Cenário de evasão do ensino superior derruba mito contra educação a distância. São Paulo, 2023. Disponível em: <https://fundacaofat.org.br/cenario-de-evasao-do-ensino-superior-derruba-mito-contra-educacao-a-distancia/>. Acesso em: 26 fev. 2025.

UNIVERSIDADE DO PORTO. Desempenho escolar de quase um terço dos alunos piorou com ensino a distância. Porto, 2022. Disponível em: <https://noticias.up.pt/2022/04/19/desempenho-escolar-de-quase-um-terco-dos-alunos-piorou-com-ensino-a-distancia/>. Acesso em: 26 fev. 2025.

CONFEDERAÇÃO NACIONAL DOS TRABALHADORES EM EDUCAÇÃO (CNTE). Pandemia ampliou desigualdade no ensino, evasão escolar e perda de aprendizagem. Brasília, 2023. Disponível em: <https://cnte.org.br/noticias/pandemia-ampliou-desigualdade-no-ensino-evasao-escolar-e-perda-de-aprendizagem-17ff>. Acesso em: 26 fev. 2025.

INSTITUTO FEDERAL FLUMINENSE (IFF). Redes sociais atrapalham desenvolvimento de alunos, diz pesquisa. Campos dos Goytacazes, 2022. Disponível em: <https://portal1.iff.edu.br/nossos-campi/campos-centro/noticias/redes-sociais-atrapalham-desenvolvimento-de-alunos-diz-pesquisa>. Acesso em: 26 fev. 2025.

KAGGLE. Online Course Student Engagement Metrics. Disponível em: <https://www.kaggle.com/datasets/thedevastator/online-course-student-engagement-metrics>. Acesso em: 24 fev. 2025.

SILVA, Rayan Crhistofer Gomes da. *Sistema inteligente para suporte acadêmico: recomendação de alunos para tutoria baseado em dados de cursos online*. 2025. Disponível em: https://github.com/RayanCrhistofer/SISTEMA-INTELIGENTE-PARA-SUORTE-ACAD-MICO-RECOMENDA-O-DE-ALUNOS-PARA-TUTORIA---PRO_APL_3-MACK. Acesso em: 27 fev. 2025.

AL-SAMARRAIE, H.; SAH, A. A. M.; FAALY, T. M. "Personalized learning analytics in online learning environments: A systematic review and future directions". *Computers & Education*, v. 154, p. 103878, 2020.

ANDERSON, T.; GARRISON, D. R.; ARCHER, W. "The community of inquiry framework: Research and practice in online learning". *The Internet and Higher Education*, v. 45, p. 100763, 2020.

BOGDANOV, E.; ULLRICH, C.; KOPER, R.; BRUSILOVSKY, P. "Recommendations in online learning environments: Systematic review and research directions". *Educational Technology & Society*, v. 22, n. 3, p. 56-72, 2019.

DANKAR, F. K.; ELMOLHIM, M. "Privacy-preserving educational data mining: A survey of methods and trends". *Educational Technology Research and Development*, v. 68, n. 2, p. 1-20, 2020.

GE, Y.; JIANG, H.; LEE, D. "Bias in recommendation systems: Challenges and solutions". *ACM Transactions on Computer-Human Interaction*, v. 27, n. 4, p. 1-23, 2020.

KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. "Deconstructing disengagement: Analyzing learner subpopulations in massive open online courses". *Learning Analytics & Knowledge*, p. 170-179, 2017.

RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. *Recommender Systems Handbook*. Springer, 2015.

MARTIN, F.; SUN, T.; WESTINE, C. D. "Examining faculty readiness for online teaching: A systematic review". *Distance Education*, v. 42, n. 1, p. 5-29, 2021.

ROMERO, C.; VENTURA, S. "Educational data mining and learning analytics: A survey of research trends, techniques and applications". *Journal of Artificial Intelligence in Education*, v. 30, n. 1, p. 3-36, 2020.

MARCOLINO, M. R. et al. Student dropout prediction through machine learning optimization: insights from moodle log data. *Scientific Reports*, v. 15, p. 9840, 2025. Disponível em: <https://doi.org/10.1038/s41598-025-93918-1>. Acesso em: 07 maio 2025.

CHONG, K. T.; IBRAHIM, N.; HUSPI, S. H.; KADIR, W. M. N. W.; ISA, M. A. A Systematic Review of Machine Learning Techniques for Predicting Student Engagement and Performance in Online Learning. *Journal of Information Technology Education: Research*, v. 24, p. 005, 2025

BELLARHMOCH, Y.; MAJJATE, H.; JEGHAL, A.; TAIRI, H.; BENJELLOUN, N. Detecting Student Engagement in an Online Learning Environment Using a Machine Learning Algorithm. *Information, LISAC Laboratory – Sidi Mohamed Ben Abdellah University, Fez, Marrocos*, 2025.

KAGGLE. Online Course Student Engagement Metrics. Disponível em: <https://www.kaggle.com/datasets/thedevastator/online-course-student-engagement-metrics>.

SILVA, Rayan Crhistofer Gomes da. *Sistema inteligente para suporte acadêmico: recomendação de alunos para tutoria baseado em dados de cursos online*. 2025. Disponível em: https://github.com/RayanCrhistofer/SISTEMA-INTELIGENTE-PARA-SUORTE-ACAD-MICO-RECOMENDA-O-DE-ALUNOS-PARA-TUTORIA---PRO_APL_3-MACK.

BURKE, Robin. Hybrid recommender systems: survey and experiments. *User modeling and user-adapted interaction*, v. 12, n. 4, p. 331–370, 2002.

COVER, Thomas M.; HART, Peter E. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, v. 13, n. 1, p. 21–27, 1967.

LI, Tian et al. Personalized Educational Recommender Systems with Transformer Architectures. IEEE Transactions on Learning Technologies, v. 14, n. 2, p. 185–197, 2021.

LÓPEZ-NICOLÁS, Carlos; RUBIO, Fernando; ORTIZ-DE-URBINA-CRIADO, Manuel. Recommendation systems for personalized learning: A review and future directions. Computers & Education, v. 173, p. 104297, 2021.

MA, Huiqiang et al. Comparative analysis of machine learning algorithms for educational prediction. Procedia Computer Science, v. 174, p. 100–105, 2020.

SU, Xiaoyuan; KONSTAN, Joseph A. Collaborative filtering for personalized recommendation. Communications of the ACM, v. 52, n. 5, p. 89–97, 2009.

ZHANG, Shuai et al. Deep learning based recommender system: A survey and new perspectives. ACM Computing Surveys, v. 52, n. 1, p. 1–38, 2019.

ZHOU, Zhiqiang et al. Predicting student performance with learning behavior data using KNN and logistic regression. International Journal of Emerging Technologies in Learning (iJET), v. 13, n. 3, p. 124–136, 2018.

CRHISTOFER, RAYAN. *Projeto no Google Colab*. Disponível em: https://colab.research.google.com/drive/1o_7v1_3priubAo2rPCj9tqYLhJ-RdcNB?usp=sharing.

CRHISTOFER, RAYAN. Apresentação Grupo 14 – Rayan, Amanda, Thabata e Tiago. YouTube, 30 mai. 2025. Disponível em: <https://www.youtube.com/watch?v=ceQVNsJyn0s>.