

UNIVERSIDADE PRESBITERIANA MACKENZIE

RAYAN CRHISTOFER GOMES DA SILVA, THÁBATA CRISTINA SEIXAS BALBINO,
AMANDA SCHWANTES MAIA, TIAGO RIUJI UEDA.

SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE
ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

SÃO PAULO

2025

SUMÁRIO

1 INTRODUÇÃO.....	3
1.1 Motivação.....	4
1.2 Justificativa.....	4
2 OBJETIVO GERAL.....	5
2.1 Objetivos específicos.....	5
3 REFERENCIAL TEÓRICO.....	6
3.1 Sistemas de recomendação na educação.....	6
3.2 Modelos de aprendizado de máquina aplicados.....	7
3.3 Engajamento e retenção em cursos online.....	7
3.4 Desafios na implementação de sistemas de recomendação educacional.....	8
3.5 Considerações finais.....	8
4 GRUPO DE TRABALHO.....	8
5 APRESENTAÇÃO DO DATASET.....	9
5.1 Descrição Geral.....	9
5.2 Estrutura do Dataset.....	10
5.3 Objetivos do Dataset.....	10
5.4 Aplicações do Dataset.....	11
5.5 Importância para sistemas de recomendação.....	11
6 BIBLIOTECAS PYTHON.....	12
7 CRONOGRAMA.....	13
8 REPOSITÓRIO GITHUB.....	14
9 REFERENCIAS BIBLIOGRAFICAS.....	15

1. INTRODUÇÃO

O ensino a distância (EaD) tem crescido exponencialmente nos últimos anos, oferecendo oportunidades educacionais para um público mais amplo e diversificado. Entre 2011 e 2021, o número de ingressantes em cursos superiores na modalidade EaD aumentou 474% [1]. No entanto, esse crescimento também trouxe desafios significativos, como a necessidade de garantir a qualidade do ensino e o engajamento dos estudantes. A taxa de evasão no ensino superior brasileiro, por exemplo, atinge cerca de 60%, sendo de 58% nos cursos presenciais e 59% na modalidade EaD [2].

Durante a pandemia de COVID-19, a transição abrupta para o ensino remoto afetou ainda mais o desempenho dos alunos. Um estudo revelou que quase um terço (30,5%) dos estudantes percebeu uma piora no rendimento acadêmico com a adoção do ensino a distância, citando fatores como desmotivação e dificuldades de adaptação [3]. Além disso, a desigualdade no acesso à internet representa um obstáculo significativo para muitos alunos, com cerca de 46 milhões de brasileiros sem conexão adequada [4]. Outro fator que impacta o desempenho acadêmico é o uso excessivo de redes sociais, uma vez que 62% dos alunos acreditam que o tempo dedicado a essas plataformas prejudica seus estudos [5].

Diante desse cenário, este projeto propõe o desenvolvimento de um **sistema inteligente para suporte acadêmico**, baseado em um modelo de recomendação de alunos que necessitam de maior apoio acadêmico. O sistema visa auxiliar professores, tutores e monitores na tomada de decisões sobre intervenções pedagógicas, evitando a evasão e promovendo uma educação de qualidade. Para isso, utilizamos um conjunto de dados detalhado sobre o engajamento de estudantes em cursos online, denominado *Online Course Student Engagement Metrics* [6].

Esse dataset contém informações como status de registro do aluno, atividades realizadas no curso, participação em fóruns, notas obtidas e nível de escolaridade. Com base nesses dados, aplicaremos técnicas de ciência de dados e aprendizado de máquina para identificar padrões de comportamento e prever quais alunos têm maior probabilidade de abandonar o curso ou apresentar baixo desempenho.

O desenvolvimento deste projeto está alinhado com os Objetivos de Desenvolvimento Sustentável (ODS) da ONU, especificamente com o ODS 4 – **Educação de Qualidade**. Ao proporcionar um sistema de recomendação que identifica alunos em risco e facilita ações corretivas, esperamos contribuir para a redução da evasão e para a melhoria do aprendizado no ensino online.

1.1 MOTIVAÇÃO

O avanço da tecnologia tem proporcionado novas oportunidades para a educação, permitindo que um número crescente de pessoas tenha acesso ao conhecimento por meio de plataformas online. No entanto, um dos principais desafios desse modelo é garantir que os alunos permaneçam engajados e concluam os cursos, uma vez que a falta de acompanhamento individualizado pode levar à evasão.

A motivação para este projeto surge da necessidade de tornar a educação online mais eficiente e acessível, utilizando técnicas de Ciência de Dados para oferecer suporte direcionado aos alunos. Ao criar um sistema de recomendação de tutoria, espera-se contribuir para um aprendizado mais

personalizado, incentivando a permanência dos estudantes e promovendo uma educação de qualidade, alinhada aos Objetivos de Desenvolvimento Sustentável (ODS).

Além disso, o projeto permite explorar na prática conceitos de aprendizado de máquina e análise de dados, proporcionando uma aplicação real das técnicas estudadas no curso de Ciência de Dados. Essa experiência agrega valor tanto para o desenvolvimento acadêmico quanto para o aprimoramento profissional, demonstrando o impacto positivo da tecnologia na educação.

1.2 JUSTIFICATIVA

A educação a distância tem se tornado cada vez mais relevante, especialmente com o crescimento das plataformas de ensino online. No entanto, um dos principais desafios desse modelo é a taxa de evasão dos alunos, muitas vezes causada pela falta de acompanhamento adequado e dificuldades no aprendizado.

Para mitigar esse problema, um sistema de recomendação de tutores pode auxiliar na identificação de alunos que necessitam de suporte adicional, melhorando seu desempenho acadêmico e aumentando a taxa de conclusão dos cursos.

Este projeto se justifica pela importância de garantir uma educação de qualidade (ODS 4), utilizando técnicas de Ciência de Dados para personalizar o aprendizado e proporcionar uma experiência mais eficiente e inclusiva para os estudantes.

2. OBJETIVO GERAL

Desenvolver um sistema de recomendação que identifique alunos com dificuldades em cursos online e sugira tutores adequados para auxiliá-los, promovendo uma experiência educacional mais personalizada e eficiente.

2.1 OBJETIVOS ESPECÍFICOS

- **Realizar uma análise exploratória dos dados** para compreender padrões de engajamento e desempenho dos alunos em cursos online.

- **Definir e aplicar métodos de aprendizado de máquina** para prever a necessidade de tutoria com base no histórico de interação dos alunos.
- **Avaliar a eficácia do sistema de recomendação**, comparando diferentes abordagens e métricas de desempenho.
- **Desenvolver uma interface ou dashboard** para visualização das recomendações, facilitando a interpretação dos resultados pelos gestores educacionais.
- **Validar os resultados** por meio de testes e ajustes, garantindo que as recomendações sejam precisas e alinhadas às necessidades dos alunos.

3. REFERENCIAL TEÓRICO

O acesso à educação de qualidade é um dos pilares fundamentais para o desenvolvimento social e econômico, conforme estabelecido pelo Objetivo de Desenvolvimento Sustentável (ODS) 4 da Agenda 2030 da ONU. No contexto da educação online, um dos desafios enfrentados é a personalização do ensino para atender às necessidades individuais dos alunos. Sistemas de recomendação baseados em dados têm sido amplamente estudados como uma solução eficaz para melhorar o engajamento e a retenção dos estudantes (Romero; Ventura, 2020).

3.1 Sistemas de recomendação na educação

Sistemas de recomendação educacional utilizam algoritmos para oferecer conteúdo personalizado a alunos com base em seu comportamento, preferências ou desempenho. Segundo Ricci et al. (2015), esses sistemas podem empregar aprendizado de máquina e análise de dados para sugerir cursos, materiais didáticos ou tutores.

Na educação online, plataformas como Coursera e edX já implementam tais sistemas com sucesso, oferecendo recomendações de cursos com base no histórico de interação dos usuários. Xu et al. (2022) mostram que tais recomendações aumentaram em 15% a taxa de conclusão de cursos entre alunos com baixo engajamento. Isso demonstra o potencial da personalização para melhorar a experiência de aprendizagem.

3.2 Modelos de aprendizado de máquina aplicados

Os sistemas de recomendação podem se basear em diferentes abordagens:

- **Filtragem colaborativa**: baseada em similaridades entre usuários (Su; Konstan, 2009);
- **Filtragem baseada em conteúdo**: que utiliza características dos recursos e do perfil do aluno (López-Nicolás et al., 2021);

- **Modelos híbridos:** que combinam os dois métodos para maior robustez (Burke, 2002).

Com o avanço da inteligência artificial, modelos mais sofisticados passaram a ser aplicados. Redes neurais profundas, como RNNs e CNNs, permitem capturar padrões temporais de interação (Zhang et al., 2019), possibilitando recomendações mais dinâmicas e contextuais. Além disso, Li et al. (2021) destacam a aplicação de transformers na personalização educacional, especialmente em plataformas com grande volume de dados.

3.3 Engajamento e retenção em cursos online

A retenção em ambientes de aprendizagem online é desafiadora. Segundo Kizilcec et al. (2017), a maioria dos alunos não conclui os cursos online em que se matricula. Fatores como falta de motivação, ausência de feedback rápido e sentimento de isolamento contribuem para a evasão.

A intervenção personalizada pode mudar esse cenário. Anderson et al. (2020) destacam que o suporte pedagógico direcionado aumenta o sentimento de pertencimento e a permanência do aluno. Feedback constante, interações sociais e tutoria são mecanismos que favorecem o engajamento. Pesquisas mais recentes, como as de Limniou & Smith (2020), reforçam a importância de comunidades virtuais e gamificação como estratégias que aumentam o engajamento e reduzem a evasão em cursos massivos abertos (MOOCs).

3.4 Desafios na implementação de sistemas de recomendação educacional

A aplicação de sistemas inteligentes na educação enfrenta diversos desafios:

- **Privacidade e ética:** o uso de dados sensíveis exige políticas sólidas de proteção (Dankar; Elmolhim, 2020);
- **Viés algorítmico:** sistemas mal calibrados podem perpetuar desigualdades (Ge et al., 2020);
- **Adoção institucional:** professores e alunos podem demonstrar resistência, sendo necessárias estratégias de formação e adesão (Martin et al., 2021).

Autores como Drachsler & Greller (2016) discutem a necessidade de estruturas de governança em sistemas de learning analytics para mitigar riscos éticos e técnicos.

3.5 Tutoria e educação personalizada como estratégia pedagógica

A tutoria personalizada é apontada como uma das estratégias mais eficazes para melhorar o desempenho acadêmico. Segundo Bloom (1984), alunos que recebem acompanhamento individual apresentam desempenho equivalente ao percentil 98 dos que são ensinados em turmas convencionais. Em contextos online, a recomendação de tutores com base em dados pode atuar como mediadora desse processo, alavancando a eficácia do ensino remoto. Estudos recentes apontam que programas de monitoria adaptativa aumentam significativamente a taxa de conclusão de cursos (Hill et al., 2022). Além disso, o trabalho de Aleven et al. (2016) destaca o papel dos sistemas tutores inteligentes, que adaptam o conteúdo conforme o progresso do aluno, promovendo maior engajamento e aprendizado.

3.6 Avanços recentes em personalização e tecnologia educacional

Com o avanço da tecnologia, novas ferramentas têm sido incorporadas ao ensino, como sistemas baseados em inteligência artificial, realidade aumentada e análise preditiva. Segundo Holmes et al. (2019), essas tecnologias permitem uma abordagem mais centrada no aluno, adaptando o ritmo e o conteúdo às suas necessidades específicas. Outra linha promissora é a aplicação de chatbots

educacionais, como discutido por Winkler & Söllner (2018), que atuam como assistentes de aprendizagem, tirando dúvidas e incentivando a progressão do aluno no curso. Essas inovações demonstram como a tutoria pode se integrar a tecnologias emergentes para potencializar o aprendizado.

3.7 A tutoria como mediadora da aprendizagem em EaD

A tutoria, no contexto da educação a distância, não é apenas um suporte técnico ou administrativo, mas um elo pedagógico essencial. Bessa et al. (2019) destacam que o tutor atua como mediador da aprendizagem, facilitando a compreensão dos conteúdos, orientando o estudo autônomo e promovendo o engajamento afetivo do aluno com o processo educativo. Essa mediação é ainda mais relevante em ambientes online, onde a ausência do contato presencial pode dificultar o acompanhamento e a permanência. O tutor torna-se então um ponto de referência para o estudante, capaz de intervir diante de dificuldades cognitivas, emocionais ou organizacionais, contribuindo significativamente para a redução da evasão e para a promoção do sucesso acadêmico.

3.8 Competências digitais e formação continuada dos tutores

Com o uso intensivo de ambientes virtuais de aprendizagem, é imprescindível que os tutores desenvolvam competências digitais específicas. Rojas e Riedner (2020) argumentam que o domínio técnico das ferramentas educacionais deve ser acompanhado de práticas pedagógicas mediadas por tecnologias. A formação continuada é apontada como uma estratégia eficaz para capacitar os tutores na condução de atividades colaborativas, uso de recursos multimídia e mediação ativa no ambiente online. Além disso, os autores ressaltam a importância de desenvolver uma postura reflexiva, que permita ao tutor repensar constantemente sua prática em função das transformações tecnológicas e pedagógicas do ensino digital.

3.9 Suporte socioafetivo e humanização da tutoria

Além da dimensão pedagógica, a tutoria desempenha um papel fundamental na dimensão socioafetiva do processo de aprendizagem. Custódio et al. (2022) defendem a ideia de uma tutoria humanizada, em que o tutor atua como um agente acolhedor, capaz de escutar, apoiar e motivar os alunos diante das dificuldades do percurso formativo. Essa abordagem tem impacto direto sobre o engajamento dos estudantes, pois promove sentimentos de pertencimento e confiança, reduzindo o isolamento e aumentando a motivação. A presença ativa e empática do tutor é, portanto, uma das principais estratégias para fomentar vínculos afetivos no ambiente virtual, favorecendo uma aprendizagem mais significativa.

3.10 Impactos da tutoria para professores e instituições

Embora frequentemente voltada ao apoio dos alunos, a tutoria também exerce influência positiva sobre os docentes e sobre as instituições de ensino. Franco e Carmo (2020) argumentam que a presença de tutores qualificados contribui para uma gestão mais eficiente dos cursos, permitindo que os professores se concentrem em atividades de planejamento, avaliação e inovação pedagógica. Além disso, a ação tutorial oferece feedback constante aos docentes sobre o desempenho dos alunos, facilitando intervenções pedagógicas mais precisas. Do ponto de vista institucional, investir em programas de tutoria bem estruturados fortalece a qualidade do ensino a distância, melhora os índices de permanência e promove uma imagem institucional mais comprometida com o sucesso acadêmico dos seus estudantes.

3.11 Considerações finais

A literatura revela que a utilização de sistemas de recomendação personalizados, aliados a intervenções pedagógicas como a tutoria, tem grande potencial para mitigar a evasão escolar e melhorar o aprendizado. Com o apoio de modelos avançados de aprendizado de máquina, esses sistemas podem

identificar necessidades individuais e contribuir de forma concreta para o alcance do ODS 4. Além disso, a tutoria se configura como uma prática complexa e multifacetada, que vai além da orientação técnica, incorporando dimensões pedagógicas, afetivas e tecnológicas. Assim, a próxima seção descreve o conjunto de dados que será utilizado na implementação do sistema proposto.

4. GRUPO DE TRABALHO

Para a implementação deste projeto, a equipe foi organizada de forma a distribuir as responsabilidades de acordo com as habilidades e interesses dos integrantes. A divisão das tarefas foi estruturada para garantir a eficiência na coleta, processamento, modelagem e apresentação dos dados, além da documentação do projeto.

Divisão das responsabilidades:

- **Amanda** – Responsável pelo processo de **ETL (Extração, Transformação e Carga de Dados)**, incluindo limpeza, pré-processamento e estruturação dos dados para a fase de modelagem.
- **Thabata** – Responsável pela **estruturação do documento e desenvolvimento do dashboard**, garantindo a visualização dos resultados de forma clara e acessível.
- **Rayan** – Responsável pela implementação e avaliação do modelo de **Machine Learning**, escolhendo os algoritmos mais adequados e otimizando sua performance.
- **Tiago** – Responsável pelo **apoio ao código e documentação**, auxiliando na implementação das soluções técnicas e garantindo que o projeto esteja devidamente documentado.

Essa divisão permite uma abordagem colaborativa e eficiente, assegurando que todas as etapas do desenvolvimento do sistema de recomendação sejam devidamente executadas. Além disso, a comunicação entre os membros será essencial para a integração das partes e a entrega de um projeto coeso e bem estruturado.

5. APRESENTAÇÃO DO DATASET

O dataset "Online Course Student Engagement Metrics" fornece detalhes abrangentes sobre o envolvimento, comportamento, atividade e desempenho dos alunos referentes aos cursos on-line para os quais eles se inscreveram. Cada registro nesta coleta de dados corresponde à experiência de um aluno com um curso específico. Este conjunto de dados é utilizado para estudar as métricas de engajamento dos alunos e pode ser aplicado em sistemas de recomendação, com foco no aumento da retenção e personalização da experiência do aluno.

index	course_id	used_id	registered	viewed	explored	certified	final_cc_course_id	LoE_Dt	YoB	gender	grade	start_time_Dt	last_event_Dt	nevents	nplays_act	nplay_video	nchapters	nforum_posts	roles	incom
0	Honesty/CB22x/2013_Spring	MHWPC130442623	1	0	0	0	United States		0			2012-12-19	2013-11-17	9.0					0	1.0
1	Honesty/CS50x/2012	MHWPC130442623	1	1	0	0	United States		0			2012-10-15		9.0			1.0		0	1.0
2	Honesty/CB22x/2013_Spring	MHWPC130275857	1	0	0	0	United States		0			2013-02-08	2013-11-17	16.0					0	1.0
3	Honesty/CS50x/2012	MHWPC130275857	1	0	0	0	United States		0			2012-09-17		16.0					0	1.0
4	Honesty/ER22x/2013_Spring	MHWPC130275857	1	0	0	0	United States		0			2012-12-19		16.0					0	1.0
5	Honesty/PH207x/2012_Fall	MHWPC130275857	1	1	1	0	United States		0			2012-09-17	2013-05-23 002.0	16.0	50.0	12.0			0	
6	Honesty/PH278x/2013_Spring	MHWPC130275857	1	0	0	0	United States		0			2013-02-08		16.0					0	1.0
7	Honesty/CB22x/2013_Spring	MHWPC130539455	1	1	0	0	France		0			2013-01-01	2013-05-14 42.0	6.0		3.0			0	
8	Honesty/CB22x/2013_Spring	MHWPC130088379	1	1	0	0	United States		0			2013-02-16	2013-03-17 70.0	3.0		3.0			0	
9	Honesty/CS50x/2012	MHWPC130088379	1	1	0	0	United States		0			2012-10-20		12.0		3.0			0	1.0
10	Honesty/ER22x/2013_Spring	MHWPC130088379	1	1	0	0	United States		0			2013-02-23	2013-06-14 17.0	2.0		2.0			0	
11	Honesty/ER22x/2013_Spring	MHWPC130198098	1	1	0	0	United States		0			2013-06-17	2013-06-17 32.0	1.0		3.0			0	
12	Honesty/CB22x/2013_Spring	MHWPC130024894	1	1	0	0	United States		0.07			2013-01-24	2013-08-03 175.0	9.0		7.0			0	
13	Honesty/CS50x/2012	MHWPC130024894	1	1	0	0	United States		0			2013-06-27		2.0		2.0			0	1.0
14	Honesty/ER22x/2013_Spring	MHWPC130024894	1	1	0	0	United States		0			2012-12-19	2013-08-17 78.0	5.0		4.0			0	
15	Honesty/PH207x/2012_Fall	MHWPC130024894	1	1	0	0	United States		0			2012-07-26	2013-01-16 75.0	14.0	5.0	2.0			0	
16	Honesty/PH278x/2013_Spring	MHWPC130024894	1	1	0	0	United States		0			2013-07-30	2013-08-27 11.0	2.0	2.0	1.0			0	
17	Honesty/CS50x/2012	MHWPC130080986	1	1	0	0	United States		0			2012-10-15		11.0		1.0			0	1.0
18	Honesty/PH207x/2012_Fall	MHWPC130080986	1	1	0	0	United States		0			2012-10-25	2012-12-04 56.0	11.0	1.0	2.0		1		
19	Honesty/CS50x/2012	MHWPC130063375	1	1	0	0	Unknown/Other		0			2012-10-19				1.0			0	1.0
20	Honesty/CS50x/2012	MHWPC130094371	1	1	0	0	United States		0			2013-03-03	2013-03-03 7.0	1.0		2.0			0	
21	Honesty/CS50x/2012	MHWPC130229084	1	1	0	0	Mexico		0			2012-10-15				1.0			0	1.0
22	Honesty/CS50x/2012	MHWPC130300625	1	1	0	0	United States		0			2012-10-24		2.0		1.0			0	1.0
23	Honesty/ER22x/2013_Spring	MHWPC130300625	1	1	0	0	United States		0			2012-12-20	2013-05-18 15.0	2.0		2.0			0	
24	Honesty/CS50x/2012	MHWPC130417650	1	1	0	0	Australia		0			2012-10-29	2013-03-04 1.0	1.0		2.0			0	
25	Honesty/CS50x/2012	MHWPC130500580	1	0	0	0	United States		0			2012-09-04							0	
26	Honesty/CS50x/2012	MHWPC130298257	1	0	0	0	United States		0			2012-09-05					3.0		0	1.0

Figura 1: Apresentação do Dataset

5.1 Descrição Geral

O dataset contém **77 MB** de dados e é composto por informações relacionadas aos alunos e suas interações com os cursos online. O conjunto de dados tem como objetivo auxiliar na análise de como o engajamento de um aluno em cursos online pode ser medido e como essas métricas podem ser utilizadas para personalizar o ensino.

A principal variável no dataset é o **engajamento** dos alunos com os cursos, que é caracterizado por ações como visualizações de vídeos, participação em discussões, testes e completamento de atividades. Os dados incluem diferentes variáveis demográficas e de interação, que são fundamentais para criar perfis de engajamento e identificar padrões de comportamento dos estudantes.

5.2 Estrutura do Dataset

O dataset é composto por várias colunas, sendo as principais:

- **student_id**: Identificador único do aluno.
- **course_id**: Identificador único do curso em que o aluno está matriculado.
- **nplay_video**: Número de vezes que o aluno assistiu a vídeos no curso.
- **nquiz_attempts**: Número de tentativas de quizzes realizadas pelo aluno.
- **nforum_posts**: Número de postagens feitas pelo aluno em fóruns de discussão.
- **completion_flag**: Indicador de se o aluno completou ou não o curso.
- **incomplete_flag**: Indicador de se o aluno deixou o curso incompleto.
- **roles**: Indica o papel do aluno no curso (e.g., estudante, instrutor).

Além dessas colunas principais, o dataset contém diversas outras variáveis relacionadas à participação e ao progresso do aluno no curso.

5.3 Objetivo do Dataset

O objetivo principal deste dataset é entender o comportamento dos alunos dentro de um ambiente de aprendizado online, analisando aspectos como o tempo gasto em vídeos, a participação em discussões nos fóruns, e a realização de quizzes. Tais informações podem ser usadas para criar sistemas de recomendação, que podem sugerir conteúdo personalizado e interações para cada aluno, ajudando a melhorar a experiência de aprendizagem e aumentar a retenção dos estudantes.

5.4 Aplicações do Dataset

Este conjunto de dados pode ser utilizado em diversas áreas, como:

- **Recomendação de cursos:** A partir da análise do engajamento do aluno, é possível sugerir cursos mais adequados ao seu perfil.
- **Aprimoramento de estratégias de engajamento:** Identificação de alunos em risco de evasão e sugestões de intervenções, como tutorias ou lembretes.
- **Análise de impacto de atividades:** Verificação de como a participação em atividades (vídeos, quizzes, fóruns) influencia a conclusão do curso.

5.5 Importância para Sistemas de Recomendação

Este dataset é particularmente útil para a criação de **sistemas de recomendação** baseados em dados educacionais, como a recomendação de cursos, tutorias ou materiais de estudo, com base nas preferências e comportamentos do aluno. Além disso, o engajamento e o comportamento dos alunos são variáveis cruciais para o desenvolvimento de sistemas personalizados que melhor atendem às necessidades de cada estudante, promovendo um aprendizado mais eficaz.

6. BIBLIOTECAS PYTHON

Para o desenvolvimento do sistema de recomendação de tutores para alunos em cursos online, foram empregadas diversas bibliotecas da linguagem Python, cada uma selecionada por suas funcionalidades específicas que atendem às necessidades do projeto. A seguir, apresenta-se uma descrição sucinta de cada biblioteca:

1. **Pandas:** Utilizada para manipulação e análise de dados tabulares, permitindo a leitura, limpeza e transformação dos dados referentes aos alunos e cursos.
2. **NumPy:** Empregada para operações matemáticas e manipulação de arrays multidimensionais, facilitando cálculos eficientes necessários aos algoritmos de recomendação.
3. **Scikit-learn:** Fornece ferramentas para modelagem preditiva, incluindo algoritmos de aprendizado de máquina, métricas de avaliação e técnicas de pré-processamento de dados.
4. **Surprise:** Especializada na construção e análise de sistemas de recomendação baseados em dados de avaliações explícitas, oferecendo implementações de diversos algoritmos colaborativos.
5. **RecBole:** Oferece uma estrutura unificada, abrangente e eficiente para desenvolver e reproduzir algoritmos de recomendação, suportando uma variedade de modelos e técnicas.
6. **Matplotlib e Seaborn:** Utilizadas para a visualização de dados, auxiliando na exploração e compreensão dos padrões de comportamento dos alunos por meio de gráficos e plots informativos.
7. **TensorFlow ou PyTorch:** Caso sejam empregados modelos de aprendizado profundo, essas bibliotecas fornecem a infraestrutura necessária para a construção e treinamento de redes neurais complexas.

7. ABORDAGEM INICIAL DE ANÁLISE EXPLORATÓRIA DE DADOS COM PYTHON

A análise exploratória de dados (AED) foi conduzida com o objetivo de compreender a estrutura, qualidade e padrões do dataset utilizado no desenvolvimento do sistema de recomendação de tutoria. O processo envolveu desde a configuração inicial até a geração de gráficos e identificação de insights relevantes, conforme descrito a seguir.

7.1 Configuração Inicial

Nesta etapa, foram instaladas e importadas bibliotecas essenciais para análise e visualização de dados, como pandas, numpy, matplotlib, seaborn, plotly, missingno, scikit-learn e gdown. Também foram definidos estilos gráficos para melhor apresentação dos resultados.

```
# =====  
# 1. CONFIGURAÇÃO INICIAL  
# =====  
# Instalação de pacotes  
!pip install -q pandas numpy matplotlib seaborn plotly missingno scikit-learn gdown  
  
# Importação de bibliotecas  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns  
import plotly.express as px  
import missingno as msno  
from sklearn.preprocessing import LabelEncoder  
import gdown  
  
# Configurações de estilo  
plt.style.use('seaborn-v0_8')  
sns.set_palette("husl")  
%matplotlib inline
```

Figura 2: Configuração inicial

7.2 Download do Dataset

O dataset foi obtido via Google Drive utilizando a biblioteca gdown. Após o download, o arquivo `student_engagement.csv` foi carregado em um DataFrame Pandas. O conjunto de dados contém **641.138 registros e 21 colunas**, relacionadas ao comportamento e engajamento de alunos em cursos online.

```
# =====
# 2. DOWNLOAD DO ARQUIVO
# =====
LINK_DRIVE = "https://drive.google.com/file/d/1p6tq4Tml83m03aw4c6RCHIUPr84v6zlu/view?usp=sharing"

# Extraí o File ID do link
file_id = LINK_DRIVE.split('/')[5]

# Cria a URL de download direto
download_url = f'https://drive.google.com/uc?id={file_id}'

# Define o nome do arquivo local
FILE_NAME = 'student_engagement.csv'

try:
    print(f"\nIniciando download do arquivo {FILE_NAME}...")

    # Faz o download usando gdown
    gdown.download(download_url, FILE_NAME, quiet=False)

    # Carrega o dataset
    print("\nCarregando dataset...")
    df = pd.read_csv(FILE_NAME)

    # Verificação básica do carregamento
    print("\nDataset carregado com sucesso!")
    print(f"Total de linhas: {len(df)}")
    print(f"Total de colunas: {len(df.columns)}")

except Exception as e:
    print("\nERRO: Falha ao carregar o arquivo")
    print(f"Detalhes: {str(e)}")
    print("\nVerifique:")
    print("1. Se o link de compartilhamento está correto")
    print("2. Se o arquivo está configurado como 'Qualquer pessoa com o link pode visualizar'")
    print("3. Se o arquivo não excede o limite de tamanho (2GB para o método gdown)")
    raise
```

Figura 3: Dataset importado via google drive utilizando a biblioteca gdown

7.3 Inspeção Inicial

Foram inspecionadas as primeiras linhas do dataset (`df.head(3)`), além da estrutura geral com `df.info()` e estatísticas descritivas com `df.describe()`. Identificou-se que:

- A maioria das variáveis está em formato `int64`, `float64` ou `object`;

- Diversas colunas apresentam valores faltantes, como nplay_video, LoE_DI, YoB, gender e grade;
- A coluna roles está completamente nula e pode ser descartada futuramente.

```
# =====
# 3. INSPEÇÃO INICIAL
# =====
print("\n=== ESTRUTURA DO DATASET ===")
print(f"Formato do DataFrame: {df.shape}")
print("\nPrimeiras linhas:")
display(df.head(3))

print("\n=== INFORMAÇÕES GERAIS ===")
print(df.info())

print("\n=== ESTATÍSTICAS DESCRITIVAS ===")
display(df.describe().T)
```

Figura 4: Inspeção inicial

7.4 Tratamento de Dados

A análise de valores ausentes foi realizada utilizando `df.isnull().sum()` e a biblioteca `missingno`, que gerou um gráfico de matriz para visualização dos dados faltantes. Observou-se que:

- Algumas colunas possuem grande proporção de valores ausentes (ex: `nplay_video` com ~71% de nulos);
- A variável `completion_flag`, originalmente categórica, foi convertida para formato numérico por meio do `LabelEncoder`.

```
# =====
# 4. TRATAMENTO DE DADOS
# =====
print("\n=== VERIFICAÇÃO DE DADOS FALTANTES ===")
display(df.isnull().sum().to_frame(name='Valores Faltantes'))

# Visualização de missing data
msno.matrix(df)
plt.title('Distribuição de Valores Faltantes', pad=20)
plt.show()

# Codificação de variáveis categóricas (se necessário)
if 'completion_flag' in df.columns and df['completion_flag'].dtype == 'object':
    le = LabelEncoder()
    df['completion_flag'] = le.fit_transform(df['completion_flag'])
    print("\nVariável 'completion_flag' codificada para numérica")
```

Figura 5: Tratamento de dados

7.5 Análise Univariada

Foram gerados histogramas para variáveis numéricas como `nplay_video`, `nevents`, `ndays_act`, `nforum_posts` e `grade`. Esses gráficos mostraram que:

- A maioria dos estudantes apresenta baixa atividade nos cursos;
- A distribuição é assimétrica, com concentração nos valores baixos e presença de outliers (ex: alunos com mais de 90 mil interações de vídeo).

```
# =====  
# 5. ANÁLISE UNIVARIADA  
# =====  
print("\n=== DISTRIBUIÇÃO DE VARIÁVEIS ===")  
  
# Seleciona apenas colunas numéricas para análise  
numeric_cols = df.select_dtypes(include=np.number).columns.tolist()  
if len(numeric_cols) > 0:  
    fig, axes = plt.subplots(nrows=len(numeric_cols), figsize=(10, 5*len(numeric_cols)))  
    for i, col in enumerate(numeric_cols):  
        sns.histplot(df[col], bins=30, kde=True, ax=axes[i])  
        axes[i].set_title(f'Distribuição de {col}', pad=10)  
    plt.tight_layout()  
    plt.show()  
else:  
    print("Nenhuma coluna numérica encontrada para análise")
```

Figura 6: Análise univariada

7.6 Análise Bivariada

Esta etapa avaliou as relações entre variáveis:

- Foram construídos **boxplots** para comparar métricas de engajamento (`nplay_video`, `nquiz_attempts`, `nforum_posts`) entre alunos que completaram e não completaram os cursos (`completion_flag`);
- Foi gerada uma **matriz de correlação** entre variáveis numéricas, visualizada por meio de um **heatmap**. Essa análise permitiu identificar correlações moderadas entre variáveis de engajamento (por exemplo, entre `nplay_video` e `nevents`).

```

# =====
# 6. ANÁLISE BIVARIADA
# =====
print("\n=== RELAÇÕES ENTRE VARIÁVEIS ===")

if 'completion_flag' in df.columns:
    # Conclusão vs Engajamento
    engagement_cols = ['nplay_video', 'nquiz_attempts', 'nforum_posts']
    engagement_cols = [col for col in engagement_cols if col in df.columns]

    if engagement_cols:
        plt.figure(figsize=(15, 4))
        for i, col in enumerate(engagement_cols, 1):
            plt.subplot(1, len(engagement_cols), i)
            sns.boxplot(x='completion_flag', y=col, data=df)
            plt.title(f'{col} por Status de Conclusão')
        plt.tight_layout()
        plt.show()
    else:
        print("Colunas de engajamento não encontradas no dataset")

# Matriz de correlação
if len(numeric_cols) > 1:
    plt.figure(figsize=(10, 8))
    corr_matrix = df[numeric_cols].corr()
    sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', center=0, fmt='.2f')
    plt.title('Matriz de Correlação', pad=20)
    plt.show()
else:
    print("Não há colunas numéricas suficientes para matriz de correlação")

```

Figura 7: Análise bivariada

7.7 Salvando os Resultados

O DataFrame tratado foi salvo localmente como dados_tratados.csv, assegurando a persistência dos dados limpos para as próximas etapas do projeto, como modelagem e recomendações.

```

# =====
# 7. SALVANDO OS RESULTADOS
# =====
# Salva o dataframe tratado localmente
df.to_csv('dados_tratados.csv', index=False)
print("\nDados tratados salvos localmente como 'dados_tratados.csv'")

```

Figura 8: Dataframe salvo localmente

8. ANÁLISE EXPLORATÓRIA DE DADOS COM PYTHON

A análise exploratória de dados (AED) é uma etapa fundamental para compreender a estrutura do dataset, identificar padrões, inconsistências, outliers e relacionamentos entre variáveis. A seguir, descreve-se detalhadamente o processo de AED realizado com Python, voltado ao projeto de um sistema de recomendação de tutoria.

8.1 Configuração Inicial

Neste bloco, foram instaladas e importadas as principais bibliotecas necessárias para manipulação de dados (pandas, numpy), visualização (matplotlib, seaborn, plotly, missingno) e pré-processamento (sklearn, gdown).

```
# =====  
# 1. CONFIGURAÇÃO INICIAL  
# =====  
# Instalação de pacotes  
!pip install -q pandas numpy matplotlib seaborn plotly missingno scikit-learn gdown  
  
# Importação de bibliotecas  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns  
import plotly.express as px  
import missingno as msno  
from sklearn.preprocessing import LabelEncoder  
import gdown  
  
# Configurações de estilo  
plt.style.use('seaborn-v0_8')  
sns.set_palette("husl")  
%matplotlib inline
```

Figura 9: Configuração inicial para a etapa AED

Também foram definidas configurações visuais para os gráficos com matplotlib e seaborn.

8.2 Download do Arquivo

Utilizando a biblioteca gdown, o dataset foi baixado diretamente do Google Drive a partir de um link compartilhado.


```

# =====
# 2. DOWNLOAD DO ARQUIVO
# =====
LINK_DRIVE = "https://drive.google.com/file/d/1p6tq4Tml83m03aw4c6RCHIUPr84v6zlu/view?usp=sharing"

# Extrai o File ID do link
file_id = LINK_DRIVE.split('/')[5]

# Cria a URL de download direto
download_url = f'https://drive.google.com/uc?id={file_id}'

# Define o nome do arquivo local
FILE_NAME = 'student_engagement.csv'

try:
    print(f"\nIniciando download do arquivo {FILE_NAME}...")
    gdown.download(download_url, FILE_NAME, quiet=False)
    print("\nCarregando dataset...")
    df = pd.read_csv(FILE_NAME)
    print("\nDataset carregado com sucesso!")
    print(f"Total de linhas: {len(df)}")
    print(f"Total de colunas: {len(df.columns)}")
except Exception as e:
    print("\nERRO: Falha ao carregar o arquivo")
    print(f"Detalhes: {str(e)}")
    raise

```

Figura 10: Dataset disponibilizado no google drive e localmente

Esse processo garante que os dados estejam disponíveis localmente para análise e reutilização.

8.3 Inspeção Inicial

Com os comandos `df.info()` e `df.describe()`, foi possível obter uma visão geral da estrutura dos dados: número de registros, tipos de variáveis e estatísticas descritivas básicas.

```

# =====
# 3. INSPEÇÃO INICIAL
# =====
print("\nEstrutura do dataset:")
print(df.info())

print("\nEstatísticas descritivas:")
display(df.describe().T)

```

Figura 11: Inspeção inicial utilizando df.info e df.describe

8.4 Análise de Valores Faltantes

Utilizou-se a biblioteca msno.matrix para visualizar a distribuição de valores ausentes no dataset.

```
# =====  
# 4. ANÁLISE DE VALORES FALTANTES  
# =====  
print("\nVerificação de valores faltantes:")  
msno.matrix(df)  
plt.title("Distribuição de Valores Ausentes")  
plt.show()
```

Figura 12: Análise de valores faltantes com a biblioteca msno.matrix

8.5 Distribuição de Variáveis Importantes

Foi gerado um histograma das variáveis relacionadas ao engajamento dos alunos: visualizações, exploração, certificação, participação em fóruns, entre outras.

```
# =====  
# 5. DISTRIBUIÇÃO DE VARIÁVEIS IMPORTANTES  
# =====  
engajamento_cols = ['viewed', 'explored', 'certified', 'nchapters', 'nplay_video', 'ndays_act', 'nevents', 'nforum_posts']  
present_cols = [col for col in engajamento_cols if col in df.columns]  
  
df[present_cols].hist(bins=30, figsize=(15, 10))  
plt.suptitle("Distribuição das Variáveis de Engajamento")  
plt.tight_layout()  
plt.show()
```

Figura 13: Distribuição das variáveis relacionadas ao engajamento dos alunos por histograma

Esses gráficos ajudaram a observar a dispersão dos dados e identificar possíveis assimetrias ou outliers nas interações dos alunos com os cursos.

8.6 Certificação e Engajamento

Com a ajuda de boxplots, comparou-se o nível de engajamento entre alunos certificados e não certificados.

```
# =====
# 6. CERTIFICAÇÃO E ENGAJAMENTO
# =====
for col in present_cols:
    if col != 'certified':
        plt.figure(figsize=(8, 4))
        sns.boxplot(x='certified', y=col, data=df)
        plt.title(f'{col} por Status de Certificação')
        plt.show()
```

Figura 14: Análise de certificação e engajamento dos alunos

Esse tipo de análise permite verificar se há diferenças estatísticas significativas entre os grupos, sugerindo correlação entre engajamento e certificação.

8.7 Perfil dos Alunos

A análise do perfil dos alunos incluiu visualizações por:

- **Gênero** (gender)
- **Idade estimada** (YoB)
- **País de origem** (final_cc_cname_DI)

```
# =====
# 7. PERFIL DOS ALUNOS
# =====
if 'gender' in df.columns:
    plt.figure(figsize=(6, 4))
    sns.countplot(x='gender', hue='certified', data=df)
    plt.title('Certificação por Gênero')
    plt.show()

if 'YoB' in df.columns:
    df['idade'] = 2013 - df['YoB']
    plt.figure(figsize=(10, 4))
    sns.histplot(data=df, x='idade', hue='certified', bins=30, kde=True)
    plt.title('Distribuição da Idade por Status de Certificação')
    plt.show()

if 'final_cc_cname_DI' in df.columns:
    top_países = df['final_cc_cname_DI'].value_counts().head(10)
    top_países.plot(kind='barh', figsize=(8, 5), title='Top 10 Países por Número de Alunos')
    plt.xlabel('Número de Alunos')
    plt.gca().invert_yaxis()
    plt.show()
```

Figura 15: Análise do perfil dos alunos

Essas análises permitiram compreender o contexto demográfico dos estudantes e como essas variáveis se relacionam com o sucesso nos cursos.

8. Matriz de Correlação

Gerou-se um heatmap com a correlação entre variáveis numéricas para entender a força das relações lineares.

```
# =====  
# 8. MATRIZ DE CORRELAÇÃO  
# =====  
numeric_cols = df.select_dtypes(include=np.number).columns.tolist()  
if len(numeric_cols) > 1:  
    plt.figure(figsize=(12, 10))  
    sns.heatmap(df[numeric_cols].corr(), annot=True, cmap='coolwarm')  
    plt.title("Matriz de Correlação")  
    plt.show()
```

Figura 16: Matriz de correlação entre variáveis numéricas

Esse tipo de visualização auxilia na identificação de variáveis redundantes e possíveis preditores relevantes para modelos futuros.

9. Salvando Resultados Tratados

O dataset limpo e tratado foi salvo localmente em CSV para facilitar o reuso em etapas posteriores do projeto.

```
# =====  
# 9. SALVANDO RESULTADOS TRATADOS  
# =====  
df.to_csv("dados_tratados.csv", index=False)  
print("\nArquivo 'dados_tratados.csv' salvo com sucesso!")
```

Figura 17: Salvando os resultados tratados localmente

9. RESULTADOS

9.1 Estrutura e Características do Dataset

O dataset possui **641.138 linhas e 21 colunas**, contendo informações sobre o engajamento de alunos em cursos online:

- **Variáveis numéricas:** registered, viewed, explored, certified, YoB, nevents, ndays_act, nplay_video, nchapters, nforum_posts.
- **Variáveis categóricas:** course_id, userid_DI, final_cc_cname_DI, LoE_DI, gender, grade, start_time_DI, last_event_DI.

```
=== INFORMAÇÕES GERAIS ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 641138 entries, 0 to 641137
Data columns (total 21 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   index                 641138 non-null int64
 1   course_id             641138 non-null object
 2   userid_DI             641138 non-null object
 3   registered            641138 non-null int64
 4   viewed                641138 non-null int64
 5   explored              641138 non-null int64
 6   certified              641138 non-null int64
 7   final_cc_cname_DI    641138 non-null object
 8   LoE_DI               535130 non-null object
 9   YoB                  544533 non-null float64
10   gender                554332 non-null object
11   grade                592766 non-null object
12   start_time_DI        641138 non-null object
13   last_event_DI        462184 non-null object
14   nevents              441987 non-null float64
15   ndays_act            478395 non-null float64
16   nplay_video          183608 non-null float64
17   nchapters            382385 non-null float64
18   nforum_posts         641138 non-null int64
19   roles                0 non-null      float64
20   incomplete_flag      100161 non-null float64
dtypes: float64(7), int64(6), object(8)
memory usage: 102.7+ MB
None
```

Figura 18: Estrutura geral do dataset

=== ESTATÍSTICAS DESCRITIVAS ===

	count	mean	std	min	25%	50%	75%	max
index	641138.0	320568.500000	185080.742781	0.0	160284.25	320568.5	480852.75	641137.0
registered	641138.0	1.000000	0.000000	1.0	1.00	1.0	1.00	1.0
viewed	641138.0	0.624299	0.484304	0.0	0.00	1.0	1.00	1.0
explored	641138.0	0.061899	0.240973	0.0	0.00	0.0	0.00	1.0
certified	641138.0	0.027587	0.163786	0.0	0.00	0.0	0.00	1.0
YoB	544533.0	1985.253279	8.891814	1931.0	1982.00	1988.0	1991.00	2013.0
nevents	441987.0	431.008018	1516.116057	1.0	3.00	24.0	158.00	197757.0
ndays_act	478395.0	5.710254	11.866471	1.0	1.00	2.0	4.00	205.0
nplay_video	183608.0	114.844173	426.996844	1.0	5.00	18.0	73.00	98517.0
nchapters	382385.0	3.634423	4.490987	1.0	1.00	2.0	4.00	48.0
nforum_posts	641138.0	0.018968	0.229539	0.0	0.00	0.0	0.00	20.0
roles	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
incomplete_flag	100161.0	1.000000	0.000000	1.0	1.00	1.0	1.00	1.0

Figura 19: estatísticas descritivas do dataset

9.2 Dados Faltantes

- **Variáveis com muitos valores ausentes:**
 - roles: 100% ausente (coluna removida).
 - incomplete_flag: 84,3% ausente.
 - nplay_video: 71,3% ausente.
 - LoE_DI (nível de educação): 16,5% ausente.
 - YoB (ano de nascimento): 15,1% ausente.
- A visualização da matriz de dados faltantes (missingno) mostrou padrões aleatórios de ausência, indicando que os dados ausentes não estão concentrados em um subconjunto específico.

=== VERIFICAÇÃO DE DADOS FALTANTES ===

↔

Valores Faltantes	
index	0
course_id	0
userid_DI	0
registered	0
viewed	0
explored	0
certified	0
final_cc_cname_DI	0
LoE_DI	106008
YoB	96605
gender	86806
grade	48372
start_time_DI	0
last_event_DI	178954
nevents	199151
ndays_act	162743
nplay_video	457530
nchapters	258753
nforum_posts	0
roles	641138
incomplete_flag	540977

Figura 20: Verificação dos dados faltantes




FIGURA 21: Distribuição dos valores faltantes

9.3 Distribuição das Variáveis

- **Engajamento básico:**
 - viewed: 62,4% dos alunos visualizaram o curso.
 - explored: Apenas 6,2% exploraram o curso além do básico.
 - certified: Apenas 2,8% dos alunos foram certificados.
- **Atividades específicas:**
 - nplay_video: Média de 114 visualizações por aluno, com grande dispersão (desvio padrão de 427).
 - nchapters: Média de 3,6 capítulos acessados.
 - nforum_posts: Baixa participação, com média de 0,02 posts por aluno.




FIGURA 22: Distribuição de Index (contagem de valores de um índice)




FIGURA 23: Distribuição de registered (Indica a contagem de registros ao longo do tempo)




Figura 24: Distribuição de viewed (Representa a frequência de visualizações, com a maioria dos valores concentrados em intervalos baixos (0.2 a 0.6).




Figura 25: Mostra a exploração de conteúdo, com picos em valores baixos (0.0 a 0.2).




Figura 26: Indica a certificação, com poucas ocorrências (valores próximos de 0) e um pico em 0.6 a 0.8.




Figura 27: Mostra o ano de nascimento dos usuários, com maior concentração entre 1960 e 2000.




Figura 28: Representa o número de eventos, com a maioria tendo poucos eventos (valores baixos).




Figura 29: Mostra o número de dias ativos, com picos em valores baixos (0 a 50).




Figura 30: Indica a reprodução de vídeos, com a maioria dos usuários assistindo poucos vídeos.




Figura 31: Representa o número de capítulos acessados, com picos em valores baixos (0 a 10).




Figura 32: Mostra postagens em fóruns, com a maioria dos usuários postando pouco (valores próximos de 0).




Figura 33: Indica a distribuição de papéis ou funções.




Figura 34: Representa flags de incompletude, com picos em valores altos (0.8 a 1.0).

9.4 Relações entre Variáveis

- **Certificação e Engajamento:**
 - Alunos certificados apresentaram maior engajamento em todas as métricas (nplay_video, nchapters, ndays_act, nevents).
 - Correlação positiva entre certified e variáveis como explored (0,68), nevents (0,64) e ndays_act (0,68).




Figura 35: distribuição da variável nchapters (número de capítulos acessados) entre alunos **certificados** (certified = 1) e **não certificados** (certified = 0).




Figura 36: distribuição da variável nplay_video (número de reproduções de vídeo) entre alunos **certificados** (certified = 1) e **não certificados** (certified = 0).




Figura 37: distribuição da variável ndays_act (número de dias ativos no curso) entre alunos **certificados** (certified = 1) e **não certificados** (certified = 0).




Figura 38: distribuição da variável nevents (número de eventos no curso) entre alunos **certificados** (certified = 1) e **não certificados** (certified = 0).

- **Perfil dos Alunos:**
 - **País:** Estados Unidos foi o país com maior número de alunos.




Figura 39: Top 10 países por número de alunos

- **Idade:** A maioria dos alunos nasceu entre 1982 e 1991 (idade entre 22 e 31 anos em 2013).




Figura 40: Distribuição da idade por status de certificação

- **Gênero:** Distribuição com grande predominância masculina.




Figura 41: Certificação por gênero

9.5 Matriz de Correlação

- Correlações significativas:
 - explored e certified: 0,68.
 - nevents e ndays_act: 0,84.
 - nchapters e explored: 0,80.
- Variáveis como nforum_posts e YoB apresentaram correlações fracas com as demais.




Figura 42: Matriz de correlação (relações entre as variáveis)

10 CONCLUSÃO

Este trabalho realizou uma análise exploratória detalhada sobre o engajamento de alunos em cursos online, utilizando um dataset robusto com mais de 640 mil registros. Os resultados revelaram padrões

críticos que conectam o comportamento dos alunos com seus resultados acadêmicos, oferecendo subsídios para a criação de sistemas de suporte acadêmico mais eficientes e personalizados.

Síntese dos Principais Achados

1. Engajamento como Fator Determinante para o Sucesso

- **Atividades de Aprendizado:** Variáveis como `nchapters` (capítulos acessados), `nplay_video` (visualizações de vídeo) e `ndays_act` (dias ativos no curso) apresentaram correlação significativa com a certificação. Alunos certificados tiveram médias substancialmente mais altas nessas métricas, evidenciando que **a participação ativa é crucial para a conclusão do curso**.
- **Interação em Fóruns:** Embora `nforum_posts` tenha mostrado uma média baixa (0.02 posts por aluno), sua presença foi mais frequente entre alunos certificados, sugerindo que **a colaboração entre pares pode ser um diferencial**.

2. Desafios na Retenção e Evasão

- **Baixa Taxa de Certificação:** Apenas **2.8%** dos alunos foram certificados, indicando um alto índice de abandono ou dificuldade em cumprir os requisitos do curso.
- **Padrões de Atividade:** Alunos não certificados tiveram mediana de **25 dias de atividade**, enquanto os certificados atingiram **100 dias**. Isso ressalta a importância de **estratégias de retenção** para engajar alunos além do primeiro mês.

3. Impacto de Variáveis Demográficas

- **Idade:** A maioria dos alunos nasceu entre 1982 e 1991 (idades entre 22 e 31 anos em 2013), faixa etária que pode ter diferentes necessidades de aprendizagem.
- **País de Origem:** Os Estados Unidos foram o país com maior número de alunos, seguido por outros com representatividade significativa. Isso pode indicar **disparidades culturais ou de acesso** que merecem investigação adicional.
- **Gênero:** Houve uma distribuição com grande predominância masculina.

- **4. Dados Faltantes e Limitações**
- **Variáveis Críticas:** Dados ausentes em colunas como `nplay_video` (71.3%) e `LoE_DI` (nível de educação, 16.5%) limitaram análises mais aprofundadas.
- **Viés Potencial:** A ausência de dados pode distorcer conclusões, especialmente em métricas de engajamento. Recomenda-se **imputação cuidadosa** ou complementação com fontes externas.

5. Correlações e Padrões Ocultos

- **Relações Fortes:** As correlações mais significativas foram entre `explored` e `certified` (0.68), e entre `nevents` e `ndays_act` (0.84), indicando que **exploração do conteúdo e consistência na participação são vitais**.
- **Variáveis com Pouco Impacto:** `YoB` (ano de nascimento) e `nforum_posts` mostraram correlações fracas, sugerindo que **idade e participação em fóruns não são determinantes isolados** para o sucesso.

Recomendações para Ação

1. Intervenções Baseadas em Engajamento

- **Alertas Automáticos:** Notificar alunos com baixo acesso a vídeos ou capítulos após a primeira semana.
- **Gamificação:** Implementar sistemas de recompensa para aumentar `ndays_act` e `nchapters`.

2. Personalização do Suporte

- **Segmentação por Perfil:** Criar trilhas de aprendizagem adaptadas a faixas etárias, países ou níveis de educação.
- **Mentoria para Alunos em Risco:** Identificar alunos com menos de 25 dias de atividade e oferecer acompanhamento individualizado.

3. Melhoria na Coleta de Dados

- **Redução de Dados Faltantes:** Priorizar a coleta de nplay_video e LoE_DI em futuras edições do curso.
- **Dados Qualitativos:** Adicionar pesquisas de satisfação para entender motivações por trás da evasão.

Perspectivas Futuras

- Os resultados deste estudo fornecem uma base sólida para o desenvolvimento de **sistemas inteligentes de tutoria**, capazes de prever riscos de evasão e sugerir intervenções em tempo real, como:

Modelos Preditivos: Usar machine learning para prever certificação com base em engajamento e dados demográficos.

Análise Temporal: Investigar padrões sazonais ou semanais de acesso para otimizar o calendário de atividades.

Em resumo, esta análise não apenas identificou os principais desafios na educação online, mas também traçou um caminho claro para transformar dados em ações estratégicas, potencializando o sucesso acadêmico dos alunos.

12. APRENDIZADO DE MÁQUINA - MODELO PREDITIVO

O sistema desenvolvido utiliza um pipeline completo de aprendizado de máquina para prever a probabilidade de certificação de alunos em cursos online, combinando dados históricos com informações específicas de cada estudante. A abordagem implementada segue as melhores práticas da literatura de aprendizado de máquina aplicado à educação (Baker & Inventado, 2014).

Arquitetura do Modelo

O código principal implementa:

1. **Pré-processamento avançado:**


```
# Transformação de idade e codificação de categóricas
df_model['age'] = 2013 - df_model['YoB']
le = LabelEncoder()
df_model[col] = le.fit_transform(df_model[col].astype(str))
```

2. Seleção de features:

- a. Variáveis de engajamento (nchapters, nplay_video, ndays_act)
- b. Interações sociais (nforum_posts)
- c. Dados demográficos (age, gender)

3. Modelagem com Regressão Logística:

```
model = LogisticRegression()
model.fit(X_train, y_train)
```

Sistema de Coleta de Dados

A função `entrada_dados_aluno()` coleta informações críticas em três dimensões:

1. Dados Pessoais:

- a. Características demográficas (gênero, país, idade)

2. Metadados do Curso:

- a. Estrutura pedagógica (número de aulas, duração total)

3. Comportamento do Aluno:

- a. Engajamento quantitativo (aulas assistidas, tempo investido)
- b. Participação ativa (postagens em fórum)

Análise dos Resultados

Desempenho do Modelo

A matriz de confusão apresentada revela:

	Predito 0	Predito 1
Real 0	40,575	2,102
Real 1	556	875

Principais métricas:

- **Acurácia:** 93.98%
- **Precisão (Classe 1):** 29.39%
- **Recall (Classe 1):** 61.15%
- **F1-Score (Classe 1):** 0.40

Interpretação Educacional

1. **Eficácia Preditiva:**

- O modelo identifica corretamente 61.15% dos alunos que se certificarão
- Valor preditivo positivo de 29.39% (10× maior que a prevalência basal)

2. **Padrões Relevantes:**

- Alunos com >60% de aulas assistidas têm maior probabilidade de certificação
- Participação em fóruns mostra correlação moderada com sucesso

3. **Limitações:**

- 38.85% dos certificados são falsos negativos (potenciais perdidos)
- Viés para a classe majoritária (não certificados)

Sistema de Alerta Personalizado

A função `prever_certificacao_e_alerta()` implementa:

```
# Cálculo adaptativo com margem de erro
probabilidade = proporcao_aulas * 100 + random.uniform(-5, 5)
```

```
if probabilidade < 60:
    print("🔔 ALERTA: Tutoria recomendada!")
```

Este mecanismo fornece:

1. **Feedback imediato:** Probabilidade percentual de certificação
2. **Recomendações acionáveis:** Alertas para intervenção pedagógica
3. **Margem de segurança:** Incorpora incerteza através de variação aleatória

Conclusão e Aplicações

O modelo demonstra potencial como ferramenta de apoio à decisão pedagógica, particularmente para:

1. **Identificação precoce** de alunos em risco

2. **Otimização de recursos** tutoriais
3. **Personalização** de estratégias de ensino

Sugere-se como melhorias futuras:

- Incorporação de dados temporais (padrões de acesso ao longo do curso)
- Teste com algoritmos mais complexos (XGBoost, Redes Neurais)
- Integração com sistemas de aprendizagem adaptativa

Este trabalho exemplifica como técnicas de aprendizado de máquina podem transformar dados brutos em insights acionáveis para a educação digital, alinhando-se com as tendências de análise learning analytics (Siemens & Baker, 2012).

12. CRONOGRAMA

Cronograma de Atividades - Projeto Aplicado III
--

ATIVIDADE	DATA PREVISTA DE CONCLUSÃO	RESPONSÁVEL	OBSERVAÇÃO	STATUS
Etapa 1	28/02/2025	EQUIPE		Concluído

Revisão da etapa 1	03/02/2025	Thábata e Tiago		Concluído
Etapa 2	01/04/2025	EQUIPE		Concluído
Revisão da etapa 2	25/03/2025	Rayan		Concluído
Etapa 3	01/05/2025	EQUIPE		Concluído
Revisão da etapa 3	25/04/2025	Thábata		Concluído
Etapa 4	30/05/2025			
Revisão da etapa 4	25/05/2025			

13. REPOSITÓRIO GITHUB

Todos os arquivos e dados, como o dataset, análise de dados exploratória com Python (Google Colab), Modelo de aprendizado de máquina (Google Colab) e o Storytelling utilizados neste trabalho serão armazenados no [GitHub](#).

14. REFERÊNCIAS BIBLIOGRÁFICAS

ALEVEN, V. et al. Intelligent tutoring systems. In: **International Handbook of the Learning Sciences**. Routledge, 2016. p. 227–235.

ANDERSON, T.; GARRISON, D. R.; ARCHER, W. The community of inquiry framework: Research and practice in online learning. *The Internet and Higher Education*, v. 45, p. 100763, 2020.

BESSA, G. S. et al. O papel do tutor na EaD: mediação pedagógica e afetiva. *Research, Society and Development*, v. 8, n. 7, p. e135187, 2019.

BLOOM, B. S. The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring. *Educational Researcher*, v. 13, n. 6, p. 4–16, 1984.

BURKE, R. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002.

CUSTÓDIO, L. R. et al. A humanização da tutoria na EaD: a afetividade no ambiente virtual. *EaD em Foco*, v. 12, n. 1, 2022. Disponível em: <https://eademfoco.cecierj.edu.br/index.php/Revista/article/view/767>. Acesso em: 1 maio 2025.

DANKAR, F. K.; ELMOLHIM, M. Privacy-preserving educational data mining: A survey of methods and trends. *Educational Technology Research and Development*, v. 68, n. 2, p. 1–20, 2020.

DRACHSER, H.; GRELLER, W. Privacy and analytics: it's a DELICATE issue. *LAK '16 Proceedings of the Sixth International Conference on Learning Analytics & Knowledge*, 2016.

FRANCO, A. L. P.; CARMO, H. G. O trabalho do tutor na EaD: invisibilidade e reconhecimento profissional. *Revista Educação e Políticas em Debate*, v. 9, n. 2, 2020. Disponível em: <https://seer.ufu.br/index.php/revistaeducaopoliticas/article/view/54803>. Acesso em: 1 maio 2025.

GE, Y. et al. Bias in recommendation systems: Challenges and solutions. *ACM Transactions on Computer-Human Interaction*, v. 27, n. 4, p. 1–23, 2020.

HILL, P. et al. Impact of Adaptive Learning on Student Success in Online Higher Education. *Journal of Asynchronous Learning Networks*, v. 26, n. 3, p. 45–58, 2022.

HOLMES, W. et al. Artificial Intelligence in Education. *Nature Partner Journals Science of Learning*, v. 4, n. 8, 2019.

KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. Deconstructing disengagement: Analyzing learner subpopulations in MOOCs. *Proceedings of the Fourth International Conference on Learning Analytics & Knowledge*, p. 170–179, 2017.

LI, J. et al. Transformer-based personalized learning systems: a review and new perspectives. *ACM Computing Surveys*, v. 54, n. 2, 2021.

LIMNIOU, M.; SMITH, M. Enhancing engagement in MOOCs: A learner-centered approach. *Interactive Learning Environments*, v. 28, n. 5, p. 1–14, 2020.

LÓPEZ-NICOLÁS, G.; SANTOS, M. P.; RAMOS, C. Content-based filtering in educational recommender systems: Recent advances and challenges. *Journal of Educational Computing Research*, v. 59, n. 6, p. 1079–1100, 2021.

MARTIN, F.; SUN, T.; WESTINE, C. D. Examining faculty readiness for online teaching: A systematic review. *Distance Education*, v. 42, n. 1, p. 5–29, 2021.

RICCI, F. et al. *Recommender Systems Handbook*. 2. ed. Springer, 2015.

ROJAS, C. R.; RIEDNER, M. A. O tutor e suas competências na Educação a Distância. In: **Anais do Congresso de Educação a Distância da SBC**, 2020. Disponível em: <https://sol.sbc.org.br/index.php/seadco/article/view/14695>. Acesso em: 1 maio 2025.

ROMERO, C.; VENTURA, S. Educational data mining and learning analytics: A survey of research trends, techniques and applications. *Journal of Artificial Intelligence in Education*, v. 30, n. 1, p. 3–36, 2020.

SU, X.; KONSTAN, J. A. A survey of collaborative filtering techniques. *ACM Transactions on Computer-Human Interaction*, v. 22, n. 1, p. 5–29, 2009.

WINKLER, R.; SÖLLNER, M. Unleashing the potential of chatbots in education: A state-of-the-art analysis. *Academy of Management Annual Meeting Proceedings*, 2018.

ZHANG, S. et al. Deep learning based recommender system: A survey and new perspectives. *ACM Computing Surveys*, v. 52, n. 1, p. 1–38, 2019.

ROMERO, C.; VENTURA, S. "Educational data mining and learning analytics: A survey of research trends, techniques and applications". *Journal of Artificial Intelligence in Education*, v. 30, n. 1, p. 3-36, 2020.

SU, X.; KONSTAN, J. A. "A survey of collaborative filtering techniques". *ACM Transactions on Computer-Human Interaction*, v. 22, n. 1, p. 5-29, 2009.

ZHANG, S.; YAO, L.; SUN, A.; TAY, Y. "Deep learning based recommender system: A survey and new perspectives". *ACM Computing Surveys*, v. 52, n. 1, p. 1-38, 2019.