

UNIVERSIDADE PRESBITERIANA MACKENZIE
RAYAN CRHISTOFER GOMES DA SILVA, THÁBATA CRISTINA SEIXAS BALBINO,
AMANDA SCHWANTES MAIA, TIAGO RIUJI UEDA.

SISTEMA INTELIGENTE PARA SUPORTE ACADÊMICO: RECOMENDAÇÃO DE
ALUNOS PARA TUTORIA BASEADO EM DADOS DE CURSOS ONLINE

SÃO PAULO
2025

1. INTRODUÇÃO	3
1.1 Motivação	4
1.2 Justificativa	4
1.3. Objetivo Geral	5
1.4 Objetivos Específicos	5
2. REFERENCIAL TEÓRICO	6
3. METODOLOGIA	6
3.1 Coleta e preparação dos dados	6
3.2 Análise exploratória de dados (EDA)	7
3.3 Tratamento de dados	7
3.4 Seleção de variáveis e construção de modelos	8
3.5 Implementação do sistema de alerta e recomendação	8
3.6 Ferramentas e bibliotecas utilizadas	8
4. REFERÊNCIAS BIBLIOGRÁFICAS	9

1. INTRODUÇÃO

O ensino a distância (EaD) tem crescido exponencialmente nos últimos anos, oferecendo oportunidades educacionais para um público mais amplo e diversificado. Entre 2011 e 2021, o número de ingressantes em cursos superiores na modalidade EaD aumentou 474% [1]. No entanto, esse crescimento também trouxe desafios significativos, como a necessidade de garantir a qualidade do ensino e o engajamento dos estudantes. A taxa de evasão no ensino superior brasileiro, por exemplo, atinge cerca de 60%, sendo de 58% nos cursos presenciais e 59% na modalidade EaD [2].

Durante a pandemia de COVID-19, a transição abrupta para o ensino remoto afetou ainda mais o desempenho dos alunos. Um estudo revelou que quase um terço (30,5%) dos estudantes percebeu uma piora no rendimento acadêmico com a adoção do ensino a distância, citando fatores como desmotivação e dificuldades de adaptação [3]. Além disso, a desigualdade no acesso à internet representa um obstáculo significativo para muitos alunos, com cerca de 46 milhões de brasileiros sem conexão adequada [4]. Outro fator que impacta o desempenho acadêmico é o uso excessivo de redes sociais, uma vez que 62% dos alunos acreditam que o tempo dedicado a essas plataformas prejudica seus estudos [5].

Diante desse cenário, este projeto propõe o desenvolvimento de um **sistema inteligente para suporte acadêmico**, baseado em um modelo de recomendação de alunos que necessitam de maior apoio acadêmico. O sistema visa auxiliar professores, tutores e monitores na tomada de decisões sobre intervenções pedagógicas, evitando a evasão e promovendo uma educação de qualidade. Para isso, utilizamos um conjunto de dados detalhado sobre o engajamento de estudantes em cursos online, denominado *Online Course Student Engagement Metrics* [6].

Esse dataset contém informações como status de registro do aluno, atividades realizadas no curso, participação em fóruns, notas obtidas e nível de escolaridade. Com base nesses dados, aplicaremos técnicas de ciência de dados e aprendizado de máquina para identificar padrões de comportamento e prever quais alunos têm maior probabilidade de abandonar o curso ou apresentar baixo desempenho.

O desenvolvimento deste projeto está alinhado com os Objetivos de Desenvolvimento Sustentável (ODS) da ONU, especificamente com o ODS 4 – **Educação de Qualidade**. Ao proporcionar um sistema de recomendação que identifica alunos em risco e facilita ações corretivas, esperamos contribuir para a redução da evasão e para a melhoria do aprendizado no ensino online.

1.1 Motivação

O avanço da tecnologia tem proporcionado novas oportunidades para a educação, permitindo que um número crescente de pessoas tenha acesso ao conhecimento por meio de plataformas online. No entanto, um dos principais desafios desse modelo é garantir que os alunos permaneçam engajados e concluam os cursos, uma vez que a falta de acompanhamento individualizado pode levar à evasão.

A motivação para este projeto surge da necessidade de tornar a educação online mais eficiente e acessível, utilizando técnicas de Ciência de Dados para oferecer suporte direcionado aos alunos. Ao criar um sistema de recomendação de tutoria, espera-se contribuir para um aprendizado mais personalizado, incentivando a permanência dos estudantes e promovendo uma educação de qualidade, alinhada aos Objetivos de Desenvolvimento Sustentável (ODS).

Além disso, o projeto permite explorar na prática conceitos de aprendizado de máquina e análise de dados, proporcionando uma aplicação real das técnicas estudadas no curso de Ciência de Dados. Essa experiência agrega valor tanto para o desenvolvimento acadêmico quanto para o aprimoramento profissional, demonstrando o impacto positivo da tecnologia na educação.

1.2 Justificativa

A educação a distância tem se tornado cada vez mais relevante, especialmente com o crescimento das plataformas de ensino online. No entanto, um dos principais desafios desse modelo é a taxa de evasão dos alunos, muitas vezes causada pela falta de acompanhamento adequado e dificuldades no aprendizado.

Para mitigar esse problema, um sistema de recomendação de tutores pode auxiliar na identificação de alunos que necessitam de suporte adicional, melhorando seu desempenho acadêmico e aumentando a taxa de conclusão dos cursos.

Este projeto se justifica pela importância de garantir uma educação de qualidade (ODS 4), utilizando técnicas de Ciência de Dados para personalizar o aprendizado e proporcionar uma experiência mais eficiente e inclusiva para os estudantes.

1.3. Objetivo Geral

Desenvolver um sistema de recomendação que identifique alunos com dificuldades em cursos online e sugira tutores adequados para auxiliá-los, promovendo uma experiência educacional mais personalizada e eficiente.

1.4 Objetivos Específicos

- **Realizar uma análise exploratória dos dados** para compreender padrões de engajamento e desempenho dos alunos em cursos online.
- **Definir e aplicar métodos de aprendizado de máquina** para prever a necessidade de tutoria com base no histórico de interação dos alunos.
- **Avaliar a eficácia do sistema de recomendação**, comparando diferentes abordagens e métricas de desempenho.
- **Desenvolver uma interface ou dashboard** para visualização das recomendações, facilitando a interpretação dos resultados pelos gestores educacionais.
- **Validar os resultados** por meio de testes e ajustes, garantindo que as recomendações sejam precisas e alinhadas às necessidades dos alunos.

2. REFERENCIAL TEÓRICO

O acesso à educação de qualidade é um dos pilares fundamentais para o desenvolvimento social e econômico, conforme estabelecido pelo Objetivo de Desenvolvimento Sustentável (ODS) 4 da Agenda 2030 da ONU. No contexto da educação online, um dos desafios enfrentados é a personalização do ensino para atender às necessidades individuais dos alunos. Sistemas de recomendação baseados em dados têm sido amplamente estudados como uma solução eficaz para melhorar o engajamento e a retenção dos estudantes (Romero; Ventura, 2020).

2.1 Sistemas de recomendação na educação

Sistemas de recomendação educacional utilizam algoritmos para oferecer conteúdo personalizado a alunos com base em seu comportamento, preferências ou desempenho. Segundo Ricci et al. (2015), esses sistemas podem empregar aprendizado de máquina e análise de dados para sugerir cursos, materiais didáticos ou tutores.

Na educação online, plataformas como Coursera e edX já implementam tais sistemas com sucesso, oferecendo recomendações de cursos com base no histórico de interação dos usuários. Xu et al. (2022) mostram que tais recomendações aumentaram em 15% a taxa de conclusão de cursos entre alunos com baixo engajamento. Isso demonstra o potencial da personalização para melhorar a experiência de aprendizagem.

2.2 Modelos de aprendizado de máquina aplicados

Os sistemas de recomendação podem se basear em diferentes abordagens:

- **Filtragem colaborativa:** baseada em similaridades entre usuários (Su; Konstan, 2009);
- **Filtragem baseada em conteúdo:** que utiliza características dos recursos e do perfil do aluno (López-Nicolás et al., 2021);
- **Modelos híbridos:** que combinam os dois métodos para maior robustez (Burke, 2002).

Com o avanço da inteligência artificial, modelos mais sofisticados passaram a ser aplicados. Redes neurais profundas, como RNNs e CNNs, permitem capturar padrões temporais de interação (Zhang et al., 2019), possibilitando recomendações mais dinâmicas e contextuais. Além disso, Li et al. (2021) destacam a aplicação de transformers na personalização educacional, especialmente em plataformas com grande volume de dados.

2.3 Engajamento e retenção em cursos online

A retenção em ambientes de aprendizagem online é desafiadora. Segundo Kizilcec et al. (2017), a maioria dos alunos não conclui os cursos online em que se matricula. Fatores como falta de motivação, ausência de feedback rápido e sentimento de isolamento contribuem para a evasão.

A intervenção personalizada pode mudar esse cenário. Anderson et al. (2020) destacam que o suporte pedagógico direcionado aumenta o sentimento de pertencimento e a permanência do aluno. Feedback constante, interações sociais e tutoria são mecanismos que favorecem o engajamento. Pesquisas mais recentes, como as de Limniou & Smith (2020), reforçam a importância de comunidades virtuais e gamificação como estratégias que aumentam o engajamento e reduzem a evasão em cursos massivos abertos (MOOCs).

2.4 Desafios na implementação de sistemas de recomendação educacional

A aplicação de sistemas inteligentes na educação enfrenta diversos desafios:

- **Privacidade e ética:** o uso de dados sensíveis exige políticas sólidas de proteção (Dankar; Elmolhim, 2020);
- **Viés algorítmico:** sistemas mal calibrados podem perpetuar desigualdades (Ge et al., 2020);

- **Adoção institucional:** professores e alunos podem demonstrar resistência, sendo necessárias estratégias de formação e adesão (Martin et al., 2021).

Autores como Drachsler & Greller (2016) discutem a necessidade de estruturas de governança em sistemas de learning analytics para mitigar riscos éticos e técnicos.

2.5 Tutoria e educação personalizada como estratégia pedagógica

A tutoria personalizada é apontada como uma das estratégias mais eficazes para melhorar o desempenho acadêmico. Segundo Bloom (1984), alunos que recebem acompanhamento individual apresentam desempenho equivalente ao percentil 98 dos que são ensinados em turmas convencionais. Em contextos online, a recomendação de tutores com base em dados pode atuar como mediadora desse processo, alavancando a eficácia do ensino remoto. Estudos recentes apontam que programas de monitoria adaptativa aumentam significativamente a taxa de conclusão de cursos (Hill et al., 2022). Além disso, o trabalho de Aleven et al. (2016) destaca o papel dos sistemas tutores inteligentes, que adaptam o conteúdo conforme o progresso do aluno, promovendo maior engajamento e aprendizado.

2.6 Avanços recentes em personalização e tecnologia educacional

Com o avanço da tecnologia, novas ferramentas têm sido incorporadas ao ensino, como sistemas baseados em inteligência artificial, realidade aumentada e análise preditiva. Segundo Holmes et al. (2019), essas tecnologias permitem uma abordagem mais centrada no aluno, adaptando o ritmo e o conteúdo às suas necessidades específicas. Outra linha promissora é a aplicação de chatbots educacionais, como discutido por Winkler & Söllner (2018), que atuam como assistentes de aprendizagem, tirando dúvidas e incentivando a progressão do aluno no curso. Essas inovações demonstram como a tutoria pode se integrar a tecnologias emergentes para potencializar o aprendizado.

2.7 A tutoria como mediadora da aprendizagem em EaD

A tutoria, no contexto da educação a distância, não é apenas um suporte técnico ou administrativo, mas um elo pedagógico essencial. Bessa et al. (2019) destacam que o tutor atua como mediador da aprendizagem, facilitando a compreensão dos conteúdos, orientando o estudo autônomo e promovendo o engajamento afetivo do aluno com o processo educativo. Essa mediação é ainda mais relevante em ambientes online, onde a ausência do contato presencial pode dificultar o acompanhamento e a permanência. O tutor torna-se então um ponto de referência para o estudante, capaz de intervir diante de dificuldades cognitivas, emocionais ou organizacionais, contribuindo significativamente para a redução da evasão e para a promoção do sucesso acadêmico.

2.8 Competências digitais e formação continuada dos tutores

Com o uso intensivo de ambientes virtuais de aprendizagem, é imprescindível que os tutores desenvolvam competências digitais específicas. Rojas e Riedner (2020) argumentam que o domínio técnico das ferramentas educacionais deve ser acompanhado de práticas pedagógicas mediadas por tecnologias. A formação continuada é apontada como uma estratégia eficaz para

capacitar os tutores na condução de atividades colaborativas, uso de recursos multimídia e mediação ativa no ambiente online. Além disso, os autores ressaltam a importância de desenvolver uma postura reflexiva, que permita ao tutor repensar constantemente sua prática em função das transformações tecnológicas e pedagógicas do ensino digital.

2.9 Suporte socioafetivo e humanização da tutoria

Além da dimensão pedagógica, a tutoria desempenha um papel fundamental na dimensão socioafetiva do processo de aprendizagem. Custódio et al. (2022) defendem a ideia de uma tutoria humanizada, em que o tutor atua como um agente acolhedor, capaz de escutar, apoiar e motivar os alunos diante das dificuldades do percurso formativo. Essa abordagem tem impacto direto sobre o engajamento dos estudantes, pois promove sentimentos de pertencimento e confiança, reduzindo o isolamento e aumentando a motivação. A presença ativa e empática do tutor é, portanto, uma das principais estratégias para fomentar vínculos afetivos no ambiente virtual, favorecendo uma aprendizagem mais significativa.

2.10 Impactos da tutoria para professores e instituições

Embora frequentemente voltada ao apoio dos alunos, a tutoria também exerce influência positiva sobre os docentes e sobre as instituições de ensino. Franco e Carmo (2020) argumentam que a presença de tutores qualificados contribui para uma gestão mais eficiente dos cursos, permitindo que os professores se concentrem em atividades de planejamento, avaliação e inovação pedagógica. Além disso, a ação tutorial oferece feedback constante aos docentes sobre o desempenho dos alunos, facilitando intervenções pedagógicas mais precisas. Do ponto de vista institucional, investir em programas de tutoria bem estruturados fortalece a qualidade do ensino a distância, melhora os índices de permanência e promove uma imagem institucional mais comprometida com o sucesso acadêmico dos seus estudantes.

2.11 Considerações finais

A literatura revela que a utilização de sistemas de recomendação personalizados, aliados a intervenções pedagógicas como a tutoria, tem grande potencial para mitigar a evasão escolar e melhorar o aprendizado. Com o apoio de modelos avançados de aprendizado de máquina, esses sistemas podem identificar necessidades individuais e contribuir de forma concreta para o alcance do ODS 4. Além disso, a tutoria se configura como uma prática complexa e multifacetada, que vai além da orientação técnica, incorporando dimensões pedagógicas, afetivas e tecnológicas. Assim, a próxima seção descreve o conjunto de dados que será utilizado na implementação do sistema proposto.

3. METODOLOGIA

Este estudo adotou uma metodologia quantitativa baseada em análise exploratória de dados (EDA) e modelagem preditiva, utilizando um dataset robusto contendo mais de 640 mil registros de alunos em cursos online. A pesquisa seguiu três etapas principais:

1. Análise descritiva do engajamento e perfil dos alunos
2. Investigação de correlações entre comportamento e desempenho
3. Desenvolvimento de recomendações para sistemas de suporte acadêmico

3.1 Coleta e Tratamento de Dados

O conjunto de dados analisado incluiu:

Variáveis Quantitativas de Engajamento:

- nchapters (número de capítulos acessados)
- nplay_video (visualizações de vídeo)
- ndays_act (dias de atividade no curso)
- nforum_posts (postagens em fóruns)

Variáveis Demográficas:

- Idade (derivada do ano de nascimento - YoB)
- Gênero
- País de origem

Pré-processamento:

- Tratamento de dados faltantes (71.3% em nplay_video, 16.5% em nível educacional)
- Transformação de variáveis (cálculo de idade, codificação de categóricas)
- Análise da distribuição desigual (apenas 2.8% de certificados)

3.2 Análise Exploratória

A investigação inicial revelou:

Principais Correlações:

- explored × certified: 0.68 (forte relação)
- nevents × ndays_act: 0.84 (alta correlação)
- nchapters × explored: 0.80

Diferenças Significativas:

- Alunos certificados mostraram:
 - 4× mais dias de atividade (mediana de 100 vs 25 dias)
 - Maior acesso a conteúdos (capítulos e vídeos)
 - Leve vantagem em interação em fóruns

Perfil Demográfico:

- Faixa etária predominante: 22-31 anos
- Maioria de alunos dos EUA
- Distribuição desigual por gênero

3.3 Limitações Metodológicas

O estudo apresentou algumas restrições:

1. Quantidade significativa de dados faltantes
2. Desbalanceamento da variável alvo (certificação)
3. Possível viés geográfico nos dados
4. Ausência de informações qualitativas complementares

3.4 Aplicações e Recomendações

Com base nos resultados, propõe-se:

Melhorias Metodológicas:

- Técnicas avançadas para tratamento de dados incompletos

- Coleta paralela de dados qualitativos
- Modelos que considerem padrões temporais

Sistemas de Apoio:

- Mecanismos de alerta baseados em:
 - Dias de inatividade
 - Baixo acesso a conteúdos
 - Padrões de interação

Esta abordagem metodológica permitiu não apenas identificar padrões críticos de engajamento, mas também estabelecer bases para o desenvolvimento de ferramentas inteligentes de suporte ao aprendizado online, com potencial para melhorar significativamente os resultados acadêmicos e reduzir taxas de evasão.

3.5 Resultados e conclusões

Este trabalho realizou uma análise exploratória detalhada sobre o engajamento de alunos em cursos online, utilizando um dataset robusto com mais de 640 mil registros. Os resultados revelaram padrões críticos que conectam o comportamento dos alunos com seus resultados acadêmicos, oferecendo subsídios para a criação de sistemas de suporte acadêmico mais eficientes e personalizados.

Síntese dos Principais Achados:

1. Engajamento como Fator Determinante para o Sucesso

- **Atividades de Aprendizado:** Variáveis como `nchapters` (capítulos acessados), `nplay_video` (visualizações de vídeo) e `ndays_act` (dias ativos no curso) apresentaram correlação significativa com a certificação. Alunos certificados tiveram médias

substancialmente mais altas nessas métricas, evidenciando que **a participação ativa é crucial para a conclusão do curso.**

- **Interação em Fóruns:** Embora `nforum_posts` tenha mostrado uma média baixa (0.02 posts por aluno), sua presença foi mais frequente entre alunos certificados, sugerindo que **a colaboração entre pares pode ser um diferencial.**

2. Desafios na Retenção e Evasão

- **Baixa Taxa de Certificação:** Apenas **2.8%** dos alunos foram certificados, indicando um alto índice de abandono ou dificuldade em cumprir os requisitos do curso.
- **Padrões de Atividade:** Alunos não certificados tiveram mediana de **25 dias de atividade**, enquanto os certificados atingiram **100 dias**. Isso ressalta a importância de **estratégias de retenção** para engajar alunos além do primeiro mês.

3. Impacto de Variáveis Demográficas

- **Idade:** A maioria dos alunos nasceu entre 1982 e 1991 (idades entre 22 e 31 anos em 2013), faixa etária que pode ter diferentes necessidades de aprendizagem.
- **País de Origem:** Os Estados Unidos foram o país com maior número de alunos, seguido por outros com representatividade significativa. Isso pode indicar **disparidades culturais ou de acesso** que merecem investigação adicional.
- **Gênero:** Houve uma distribuição com grande predominância masculina.

- **4. Dados Faltantes e Limitações**
- **Variáveis Críticas:** Dados ausentes em colunas como nplay_video (71.3%) e LoE_DI (nível de educação, 16.5%) limitaram análises mais aprofundadas.
- **Viés Potencial:** A ausência de dados pode distorcer conclusões, especialmente em métricas de engajamento. Recomenda-se **imputação cuidadosa** ou complementação com fontes externas.

5. Correlações e Padrões Ocultos

- **Relações Fortes:** As correlações mais significativas foram entre explored e certified (0.68), e entre nevents e ndays_act (0.84), indicando que **exploração do conteúdo e consistência na participação são vitais**.
- **Variáveis com Pouco Impacto:** YoB (ano de nascimento) e nforum_posts mostraram correlações fracas, sugerindo que **idade e participação em fóruns não são determinantes isolados** para o sucesso.

Recomendações para Ação

1. Intervenções Baseadas em Engajamento

- **Alertas Automáticos:** Notificar alunos com baixo acesso a vídeos ou capítulos após a primeira semana.
- **Gamificação:** Implementar sistemas de recompensa para aumentar ndays_act e nchapters.

2. Personalização do Suporte

- **Segmentação por Perfil:** Criar trilhas de aprendizagem adaptadas a faixas etárias, países ou níveis de educação.
- **Mentoria para Alunos em Risco:** Identificar alunos com menos de 25 dias de atividade e oferecer acompanhamento individualizado.

3. Melhoria na Coleta de Dados

- **Redução de Dados Faltantes:** Priorizar a coleta de nplay_video e LoE_DI em futuras edições do curso.
- **Dados Qualitativos:** Adicionar pesquisas de satisfação para entender motivações por trás da evasão.

Perspectivas Futuras

- Os resultados deste estudo fornecem uma base sólida para o desenvolvimento de **sistemas inteligentes de tutoria**, capazes de prever riscos de evasão e sugerir intervenções em tempo real, como:

Modelos Preditivos: Usar machine learning para prever certificação com base em engajamento e dados demográficos.

Análise Temporal: Investigar padrões sazonais ou semanais de acesso para otimizar o calendário de atividades.

Em resumo, esta análise não apenas identificou os principais desafios na educação online, mas também traçou um caminho claro para transformar dados em ações estratégicas, potencializando o sucesso acadêmico dos alunos.

O modelo demonstra potencial como ferramenta de apoio à decisão pedagógica, particularmente para:

1. **Identificação precoce** de alunos em risco
2. **Otimização de recursos** tutoriais
3. **Personalização** de estratégias de ensino

Sugere-se como melhorias futuras:

- Incorporação de dados temporais (padrões de acesso ao longo do curso)
- Teste com algoritmos mais complexos (XGBoost, Redes Neurais)
- Integração com sistemas de aprendizagem adaptativa.

Em resumo, esta análise não apenas identificou os principais desafios na educação online, mas também traçou um caminho claro para transformar dados em ações estratégicas, potencializando o sucesso acadêmico dos alunos.

3.6 Modelagem Preditiva com Aprendizado de Máquina

O estudo implementou um pipeline completo de aprendizado de máquina para prever a probabilidade de certificação de alunos em cursos online, seguindo as melhores práticas da literatura da área. A abordagem combinou técnicas de pré-processamento de dados, seleção de variáveis e modelagem estatística para criar um sistema preditivo integrado.

Processo de Desenvolvimento do Modelo:

1. Pré-processamento dos Dados:

- a. Transformação da variável ano de nascimento (YoB) em idade atual do aluno
- b. Codificação numérica de variáveis categóricas como gênero e país de origem
- c. Normalização das variáveis numéricas para mesma escala

2. Seleção de Variáveis:

- a. Foram selecionadas três categorias de preditores:
 - i. *Variáveis de engajamento*: número de capítulos acessados, visualizações de vídeo e dias ativos no curso
 - ii. *Interação social*: quantidade de postagens em fóruns de discussão
 - iii. *Dados demográficos*: idade e gênero dos alunos

3. Construção do Modelo:

- a. Adotou-se a Regressão Logística como algoritmo principal
- b. O modelo foi treinado utilizando 70% dos dados disponíveis
- c. Os 30% restantes foram reservados para validação do desempenho

3.7 Sistema de Coleta e Processamento de Dados

O sistema desenvolvido coleta e processa informações em três dimensões principais:

1. Dados Pessoais:

- a. Características demográficas como gênero, país de origem e idade
- b. Histórico educacional prévio quando disponível

2. Metadados do Curso:

- a. Estrutura pedagógica incluindo número total de aulas
- b. Duração estimada do curso em horas

3. Comportamento do Aluno:

- a. Métricas quantitativas de engajamento como aulas assistidas
- b. Tempo médio dedicado ao curso por semana
- c. Nível de participação em atividades colaborativas

3.8 Avaliação do Modelo Preditivo

Desempenho do Sistema:

O modelo demonstrou capacidade de identificar corretamente 61,15% dos alunos que obtiveram certificação, com valor preditivo positivo dez vezes superior à taxa basal de certificação na amostra. A acurácia global atingiu 93,98%, embora a precisão para a classe positiva (certificados) tenha ficado em 29,39%, reflexo da desproporção entre as classes.

Principais Padrões Identificados:

- Alunos que acessaram mais de 60% do conteúdo tiveram probabilidade significativamente maior de certificação

- A participação em fóruns, embora menos frequente, mostrou associação positiva com o sucesso
- A consistência na participação (dias ativos) foi o fator mais fortemente correlacionado com a certificação

3.9 Mecanismo de Alerta e Intervenção

O sistema incorpora um módulo de alerta que:

1. Calcula a probabilidade estimada de certificação para cada aluno
2. Adiciona uma margem de segurança de $\pm 5\%$ para evitar falsos positivos
3. Gera notificações automáticas quando a probabilidade cai abaixo de 60%
4. Fornece recomendações específicas baseadas nos padrões de engajamento

Quando um aluno é identificado como em risco, o sistema sugere intervenções como:

- Sessões de tutoria individualizada
- Lembretes para acessar conteúdos pendentes
- Incentivos para participação em atividades colaborativas

3.10 Limitações e Desafios

A abordagem apresentou algumas limitações importantes:

1. Problemas de Desbalanceamento:

A baixa taxa de certificação (2,8%) dificultou a identificação de padrões

- a. O modelo tendeu a favorecer a classe majoritária (não certificados)

2. Dados Faltantes:

- a. Variáveis importantes como visualizações de vídeo tinham mais de 70% de valores ausentes
- b. Informações sobre nível educacional estavam incompletas para 16,5% dos casos

3. Desafios de Implementação:

- a. A taxa de falsos negativos (38,85%) indica que muitos alunos certificados não foram identificados
- b. A precisão relativamente baixa para a classe positiva requer ajustes contínuos

Esta metodologia integrada permitiu desenvolver um sistema preditivo com aplicações práticas na gestão educacional, oferecendo ferramentas para identificação precoce de alunos em risco e personalização de estratégias de ensino.

4. REFERÊNCIAS BIBLIOGRÁFICAS

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). Ensino a distância cresce 474% em uma década. Brasília, 2022. Disponível em: <https://www.gov.br/inep/pt-br/assuntos/noticias/censo-da-educacao-superior/ensino-a-distancia-cresce-474-em-uma-decada>. Acesso em: 26 fev. 2025.

FUNDAÇÃO DE APOIO À TECNOLOGIA (FAT). Cenário de evasão do ensino superior derruba mito contra educação a distância. São Paulo, 2023. Disponível em: <https://fundacaofat.org.br/cenario-de-evacao-do-ensino-superior-derruba-mito-contra-educacao-a-distancia/>. Acesso em: 26 fev. 2025.

UNIVERSIDADE DO PORTO. Desempenho escolar de quase um terço dos alunos piorou com ensino a distância. Porto, 2022. Disponível em: <https://noticias.up.pt/2022/04/19/desempenho-escolar-de-quase-um-terco-dos-alunos-piorou-com-ensino-a-distancia/>. Acesso em: 26 fev. 2025.

CONFEDERAÇÃO NACIONAL DOS TRABALHADORES EM EDUCAÇÃO (CNTE). Pandemia ampliou desigualdade no ensino, evasão escolar e perda de aprendizagem. Brasília, 2023. Disponível em: <https://cnte.org.br/noticias/pandemia-ampliou-desigualdade-no-ensino-evacao-escolar-e-perda-de-aprendizagem-17ff>. Acesso em: 26 fev. 2025.

INSTITUTO FEDERAL FLUMINENSE (IFF). Redes sociais atrapalham desenvolvimento de alunos, diz pesquisa. Campos dos Goytacazes, 2022. Disponível em: <https://portal1.iff.edu.br/nossos-campi/campos-centro/noticias/redes-sociais-atrapalham-desenvolvimento-de-alunos-diz-pesquisa>. Acesso em: 26 fev. 2025.

KAGGLE. Online Course Student Engagement Metrics. Disponível em: <https://www.kaggle.com/datasets/thedevastator/online-course-student-engagement-metrics>. Acesso em: 24 fev. 2025.

SILVA, Rayan Crhistofer Gomes da. *Sistema inteligente para suporte acadêmico: recomendação de alunos para tutoria baseado em dados de cursos online*. 2025. Disponível em: https://github.com/RayanCrhistofer/SISTEMA-INTELIGENTE-PARA-SUPORTE-ACAD-MICO-RECOMENDA-O-DE-ALUNOS-PARA-TUTORIA---PRO_APL_3-MACK. Acesso em: 27 fev. 2025.

AL-SAMARRAIE, H.; SAH, A. A. M.; FAALY, T. M. "Personalized learning analytics in online learning environments: A systematic review and future directions". *Computers & Education*, v. 154, p. 103878, 2020.

ANDERSON, T.; GARRISON, D. R.; ARCHER, W. "The community of inquiry framework: Research and practice in online learning". *The Internet and Higher Education*, v. 45, p. 100763, 2020.

BOGDANOV, E.; ULLRICH, C.; KOPER, R.; BRUSILOVSKY, P. "Recommendations in online learning environments: Systematic review and research directions". *Educational Technology & Society*, v. 22, n. 3, p. 56-72, 2019.

BURKE, R. "Hybrid recommender systems: Survey and experiments". *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331-370, 2002.

DANKAR, F. K.; ELMOLHIM, M. "Privacy-preserving educational data mining: A survey of methods and trends". *Educational Technology Research and Development*, v. 68, n. 2, p. 1-20, 2020.

GE, Y.; JIANG, H.; LEE, D. "Bias in recommendation systems: Challenges and solutions". *ACM Transactions on Computer-Human Interaction*, v. 27, n. 4, p. 1-23, 2020.

KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. "Deconstructing disengagement: Analyzing learner subpopulations in massive open online courses". *Learning Analytics & Knowledge*, p. 170-179, 2017.

LÓPEZ-NICOLÁS, G.; SANTOS, M. P.; RAMOS, C. "Content-based filtering in educational recommender systems: Recent advances and challenges". *Journal of Educational Computing Research*, v. 59, n. 6, p. 1079-1100, 2021.

RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. B. *Recommender Systems Handbook*. Springer, 2015.

MARTIN, F.; SUN, T.; WESTINE, C. D. "Examining faculty readiness for online teaching: A systematic review". *Distance Education*, v. 42, n. 1, p. 5-29, 2021.

ROMERO, C.; VENTURA, S. "Educational data mining and learning analytics: A survey of research trends, techniques and applications". *Journal of Artificial Intelligence in Education*, v. 30, n. 1, p. 3-36, 2020.

SU, X.; KONSTAN, J. A. "A survey of collaborative filtering techniques". *ACM Transactions on Computer-Human Interaction*, v. 22, n. 1, p. 5-29, 2009.

ZHANG, S.; YAO, L.; SUN, A.; TAY, Y. "Deep learning based recommender system: A survey and new perspectives". *ACM Computing Surveys*, v. 52, n. 1, p. 1-38, 2019.

MARCOLINO, M. R. et al. Student dropout prediction through machine learning optimization: insights from moodle log data. *Scientific Reports*, v. 15, p. 9840, 2025. Disponível em: <https://doi.org/10.1038/s41598-025-93918-1>. Acesso em: 07 maio 2025.

CHONG, K. T.; IBRAHIM, N.; HUSPI, S. H.; KADIR, W. M. N. W.; ISA, M. A. A Systematic Review of Machine Learning Techniques for Predicting Student Engagement and Performance in Online Learning. *Journal of Information Technology Education: Research*, v. 24, p. 005, 2025

BELLARHMOCH, Y.; MAJJATE, H.; JEGHAL, A.; TAIRI, H.; BENJELLOUN, N. Detecting Student Engagement in an Online Learning Environment Using a Machine Learning Algorithm. *Information, LISAC Laboratory – Sidi Mohamed Ben Abdellah University, Fez, Marrocos*, 2025.

KAGGLE. Online Course Student Engagement Metrics. Disponível em: <https://www.kaggle.com/datasets/thedevastator/online-course-student-engagement-metrics>.

SILVA, Rayan Crhistofer Gomes da. *Sistema inteligente para suporte acadêmico: recomendação de alunos para tutoria baseado em dados de cursos online*. 2025. Disponível em: https://github.com/RayanCrhistofer/SISTEMA-INTELIGENTE-PARA-SUPORTE-ACAD-MICO-RECOMENDA-O-DE-ALUNOS-PARA-TUTORIA---PRO_APL_3-MACK.